

如何讲好你的经济学故事？

——应用计量（回归与结构模型）方法篇



许文立
安徽大学经济学院财政系
E-mail: xuweny87@163.com
2021-2022学年第二学期

第一讲 好的经验研究

- 1.1 经验研究的流行形式
- 1.2 回归分析基础
- 1.3 经验研究评价
- 1.4 面板数据模型基础

1.1 经济学论文的流行形式

- 0 题目
- 00 摘要（关键词）
- 1 引言
- 2 文献综述
- 3 理论分析（理论模型）
- 4 经验结果
- 5 结论及政策含义
- 6 参考文献

想法 (IDEA)



◆可遇不可求（开创性的）

◆遍地是黄金

◆“水喝多了，总会有尿（料）”——
——季羨林

题目

◆ 标题（标题+副标题）

- 《污染、健康与不平等——跨越“环境健康贫困”陷阱》
（《管理世界》2015年第9期）

◆ 流行的标题形式

➤ 三段式（二段式）：《**A、B与C**》、《**A与B**》

- 《污染、健康与不平等》《管理世界》2015年第9期
- 《人口老龄化、税收负担与财政可持续性》《经济研究》2015年第8期》
- Neoclassical Growth, the J Curve for Abatement, and the Inverted U Curve for Pollution, JEEM, 1995, 29
- The Environment and Directed Technical Change, AER, 2012, 102（1）
- 《公众诉求与城市环境治理》《管理世界》2013年第6期

◆流行的标题形式

➤问句式:

- 《公共支出归宿：中国政府公共服务落实到贫困人口手中了吗?》 《管理世界》 2007年第4期
- 《谁从增加的财政转移支付中受益? 》 《财贸经济》 2012年第4期
- Can Baumol's model of unbalanced growth contribute to explaining the secular rise in health care expenditure? An alternative test, Applied Economics, 2011, 42 (2)

文献综述

相关性

与研究主题高度相关，切记跑偏

前沿性

反映与研究主题相关领域的最前沿研究进展，也就是研究到了哪一步

理性的批判

总结研究进展，理性的从经济学的学理出发，批判现有研究的不足

参考：《文献综述的写法》

理论分析（模型）



◆流行形式：理论分析+假设

➤ 具体形式一：理论机制论述+假设

➤ Example 1

有些研究者分析，在他们的发展过程中经历了随着收入的增长环境质量先下降，而后随着收入水平的继续提高，环境质量开始改善（Grossman G. M.和 Krueger A. B., 1995），这就是环境库兹涅茨曲线假说。环境质量与人均收入呈现倒“U”型或“N”型关系。中国环境库兹涅茨曲线存在性的研究并没有得出一致结论，有的学者认为中国环境库兹涅茨曲线存在拐点（蔡昉等，2008；林伯强等，2009），有的学者则认为中国环境质量与经济增长并没有表现出显著的环境库兹涅茨曲线（刘笑萍等，2009），而有的学者认为中国的环境污染与其经济增长之间关系不确定（张红凤等，2009）。因此，本文给出第四个待检验假设：↵

假设4：中国存在“S”型环境库兹涅茨曲线，即中国环境支出与人均收入呈现倒“U”型关系，环境质量与经济增长之间则存在“S”型曲线关系，但表现出较弱的稳健性。↵

◆流行形式：理论分析+假设

➤ 具体形式二：理论模型+假设

➤ Example 2

将公式（5）写成 $C_{1t} = \frac{TC_{1t}}{Y_{1t}} = \frac{TC_{1t}}{L_t} \frac{L_t}{Y_t} \frac{Y_t}{Y_{1t}}$ ，其中 N 为总人口，定义 $c_{1t} = \frac{TC_{1t}}{L_t}$ ，表示人均环境公共支出，那么 $\Delta \ln c_{1t} = \Delta \ln C_{1t} + \Delta \ln y_t$ ，则我们可以得到

$$\Delta \ln c_{1t} = \Delta \ln C_{1t} + \Delta \ln y_t = (r_2 - r_1) + \Delta \ln y_t = \frac{1}{l_t} (\Delta \ln W - \Delta \ln y_t) + \Delta \ln y_t \quad (12)$$

公式（12）表明，清洁型生产部门的单位支出与该部门的劳动投入占全行业劳动份额、平均工资增长率、人均产出增长率有关。通过理论分析，可以得到以下三个待检验假设：

假设 1：中国的人均环境公共支出增长“患有”鲍莫尔成本疾病，即是说中国的人均环境公共支出增长由污染型部门与清洁型部门生产率差异引起。

假设 2：中国的人均环境公共支出增长具有恩格尔效应，即是说中国的人均环境公共支出增长率随着人均产出增长率的加快而变快。


假设 3：中国的人均环境公共支出增长的恩格尔效应大于鲍莫尔效应。

数据的统计特征

表 1 2013 年 6 月 18 日-2014 年 9 月 26 日 CEEX 碳排放权交易对数收益统计特征

序列期间	样本数	最大值	最小值	均值	标准差	方差	偏度	峰度
2013/6/18 -2014/9/26	268	0.31	-0.12	0.0025	0.058	0.0033	0.638	5.55

◆ **收益均值：**0.0025，正的收益有利于碳排放交易市场的发展；



◆ **偏度：**0.638，样本数据呈现右偏

◆ **峰度：**5.55，样本数据带有尖峰

◆ **右图**呈现了CEEX日对数收益的经验分布图，其中包括核密度估计曲线和正态分布曲线。从核密度估计曲线与正态分布曲线的对比明显可以看出，样本数据的非对称性、尖峰和右厚尾。

估计结果解读

根据上述部分的理论分析,人均环境支出增长率与调整鲍莫尔变量和人均产出增长率有关,并结合前人的相关研究,本文建立如下回归方程^①

$$\Delta lnc_{it} = \alpha_0 + \alpha_1 \frac{1}{l_{it}} (\Delta \ln W_{it} - \Delta \ln y_{it}) + \alpha_2 \Delta \ln y_{it} + \mathbf{Z}_{it} \boldsymbol{\beta} + u_i + \varepsilon_{it} \quad (13) \quad ^\text{①}$$

其中, α_0 为截距项, α_1 为鲍莫尔变量系数; $\mathbf{Z}_{it}$ 为控制变量向量, $\boldsymbol{\beta}$ 为控制变量系数列向量; u_i 为个体特征; ε_{it} 为随机扰动项。^①

表 2 回归结果

Δlnc_{it}	(1) -FE	(2) -RE(GLS)	(3) -RE(MLE)
ABV_{it}	0.835* (0.430)	0.604* (0.345)	0.604* (0.344)
$\Delta \ln y_{it}$	1.462** (0.615)	1.049** (0.497)	1.049** (0.511)
Cons.	0.025** (0.055)	0.063 (0.046)	0.063 (0.049)
个体效应	控制	控制	控制
Sigma_ u_i	0.075	0	0
Sigma_ ε_{it}	0.220	0.220	0.213

注: (1) 括号中列出稳健标准误; (2) ***, **, * 分别表示 1%、5%、10% 水平下显著。

估计结果解读

表 3 增加控制变量的稳健性分析结果

$\Delta \ln c_{it}$	(4)	(5) -	(6) -	(7)	(8) -	(9) -
	-FE	RE(GLS)	RE(MLE)	-FE	RE(GLS)	RE(MLE)
ABV_{it}	0.816* (0.431)	0.624** (0.339)	0.624* (0.341)	0.822* (0.432)	0.624* (0.340)	0.624* (0.343)
$\Delta \ln y_{it}$	2.154** (0.805)	2.634*** (0.761)	2.634*** (0.928)	2.211*** (0.662)	2.636*** (0.714)	2.636*** (1.009)
$\Delta \ln y_{it} 2$	-4.216 (4.097)	-9.339** (4.026)	-9.339** (4.583)	-6.057 (7.298)	-9.393 (8.506)	-9.393 (11.705)
$\Delta \ln y_{it} 3$				8.972 (44.554)	0.260 (44.207)	0.260 (51.328)
Cons.	0.007 (0.055)	0.017 (0.043)	0.017 (0.053)	0.009 (0.060)	0.017 (0.044)	0.017 (0.054)
个体效应	控制	控制	控制	控制	控制	控制
Sigma_{u_i}	0.072	0	0	0.072	0	0
$\text{Sigma}_{\varepsilon_{it}}$	0.221	0.220	0.210	0.221	0.221	0.210

注：(1) 括号中列出稳健标准误；(2) ***、**、*分别表示 1%、5%、10%水平下显著。

进一步讨论

从稳健性检验的结果来看,加入人均收入平方项 $\Delta \ln y_{it}^2$ 后,其回归系数为-4.216和-9.339 人均收入平方项系数符号为负号,即是说中国人均环境公共支出增长率与人均收入增长率呈现倒“U”型关系,即中国存在倒“U”型环境库兹涅茨曲线,中国环境公共支出增长速度随着人均收入的增长速度加快,先上升,到达拐点E后又下降,如图1所示。但从回归模型的固定效应和随机效应来看,中国环境库兹涅茨曲线假说成立具有较弱的稳健性,从回归方程(4)、(5)、(6)、(8)和(10)中可以看出,人均收入平方项的系数在固定效应模型中均不显著,而随机效应模型中均在10%的置信水平下显著。




图1 中国的倒“U”型环境库兹涅茨曲线

不足与展望

- ◆ 不足
- ◆ 进一步的研究方向



参考文献

- ◆国内外顶级期刊上的文章
- ◆大牛们的文章和著作
- ◆顶级研究机构的研究报告或著作
- ◆政府文件
- ◆30-40篇左右（没有硬性规定）

引言

◆研究背景

- 与国家或世界大发展趋势相联系，凸显出文章主题的重要性，尤其是要显得**高大上**

◆研究意义（价值）

- 不要泛泛而谈，具体论述研究主题的价值

◆精炼的研究内容和目的

- 一定要精炼，让人知道你要研究什么，但是又不能让人知道你研究的是什么，“犹抱琵琶半遮面”

摘要

◆成也摘要，败也摘要

- ◆ 这个我也在学习之中☹...
 - ◆ 第一句话写十分精炼的意义
 - ◆ 第二句话先你的创新点（精炼）
 - ◆ 后面全部写你的研究结论及政策^y含义
 - ◆ 大概400字左右
-
- ◆ 我们一起努力学习、进步

第二讲 因果推断

经验研究花园里的F4



David Card

对劳动经济学实证研究的贡献




Joshua D. Angrist

对因果关系分析方法的贡献



Guido W. Imbens

对因果关系分析方法的贡献





Alan Krueger

对劳动经济学实证研究

20世纪90年代开始对劳动经济学和因果识别框架的改进


2.2 一图含万言：因果图

- 因果图如下：




- 每个节点（圆形）都是一个随机变量；
- 用箭头来表示一个变量导致了另一个变量，例如，左图Z导致了X，U导致了X和Y；
- 右图中，教育会增加未来收入，IQ会增加教育年限和未来收入

2.2 一图含万言：因果图



- 如左图所示：A导致B，B导致C等等；
- 两个概念：独立性与条件独立性；
- 箭头的方向就是独立流方向，即B独立于A，C独立于B；
- 当独立流中间存在一个变量，那么，独立性就被堵塞了；
- 这个时候，我们要说，基于条件Y，Z独立于X；



2.2 一图含万言：后门



- 如上图所示：交叉因果图结构：一个变量导致两个结果；
- 独立流就是箭头向后，我们称之为“后门路径(backdoor path)”；
- 如果我们不知道你的IQ，但知道你的教育年限，那么，我们也可以推断出当前收入。因为我们知道你读了研究生，就可以知道你的IQ肯定不低，然后这又会导致你的收入水平不低；
- 如果我们知道你的IQ，那么，就可以说，条件于IQ，教育年限与收入水平是独立的；因为通过IQ可以完全推断你的收入，再知道教育年限，对于收入推断没有额外的用处。

2.2 一图含万言：后门

- 一般来说，两个变量有共同的原因，那么，这两个变量就是相互依赖的；
- 但条件于这个共同原因，两个变量就独立了；
- 另一种情形：对撞因果图结构——两个变量指向同一个变量；



- 如上图所示，这种情形，我们称之为“共同效应”；
- 一般来说，条件于共同效应C或X，会使得两个变量A和B变依赖关系；
- 不要条件于共同效应，要关闭它。

2.3 回归分析基础

- 班级规模对学生成绩的影响：

$$\beta_{ClassSize} = \frac{ScoreChange}{ClasssizeChange} = \frac{\Delta Score}{\Delta ClassSize}$$

- β 表示班级规模变化引起的成绩变化。如果幸运地知道了 $\beta=-0.5$ 。那么，院长问班级规模没缩减10名学生，我们就可以知道学生成绩平均提高 $(-0.5) * (-10) = 5$ 。
- 不幸，不知道 β 。但我们能观测到班级规模和分数。我们学过一点计量：

$$Score = \beta_0 + \beta_{ClassSize} \times ClassSize$$

$$Score = \beta_0 + \beta_{ClassSize} \times ClassSize + OtherFactors$$


- 一元回归

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

- 特别注意：** u 是误差项，里面包含了除 X 外所有影响 Y 的因素。
- 我们能观测到班级规模 X ，学生成绩 Y ，现在的任务就是要把这个系数 β_1 估计出来。

Table 1: 测试分数与师生比的分布

	样本量	均值	标准差	分位数		
				10%	50%	95%
学生-老师比	420	19.64	1.89	17.35	19.72	22.65
测试分数	420	654.16	19.05	630.38	654.45	685.5



- 我们最关心的是 β_1 ，那么我们如何用420个样本数据来估计出这个系数呢？
- 最常用的就是最小二乘法（OLS）。
- 有一大堆推导，感兴趣的可以看看我的讲稿。
- 我们生活在一个便捷的时代，因为有stata和其他软件：



$$\hat{Y} = 698.9 - 2.28 \times X$$

Source	SS	df	MS	Number of obs	=	420
Model	7794.11004	1	7794.11004	F(1, 418)	=	22.58
Residual	144315.484	418	345.252353	Prob > F	=	0.0000
				R-squared	=	0.0512
				Adj R-squared	=	0.0490
Total	152109.594	419	363.030056	Root MSE	=	18.581

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
str	-2.279808	.4798256	-4.75	0.000	-3.22298	-1.336637
_cons	698.933	9.467491	73.82	0.000	680.3231	717.5428

- 在这个回归结果中我们要关注的除了 β 之外，还有5个结果很重要。
- 第一个 $R^2=0.0512$ ，越大拟合越好；
- 第二个 $MSE=18.581$ ，越小拟合越好。
- 这两个都是检验回归方程对数据的拟合程度。


- 但是，在实践中，我们常常得到的 R^2 很小，而且很多paper中这个值也很小。为什么也可以？
- 特别注意：事实上， R^2 很小（或者MSE很大）本身并不能说明回归的“好坏”。很小的 R^2 只是表明，除了X之外，还有其他重要的因素影响Y。但是较小的 R^2 （或者较大MSE）并不能给出缺失了什么重要因素。它们仅仅说明现有的X只能解释Y方差的较小部分。
- 第三是估计系数的标准误S.E.=0.48;
- 第四是t统计量， $t=-4.75$;
- 第五是p值， $p=0.000$ 。
- 注意：（1） $t=\beta/S.E.$ ；（2）t值与临界值比较得到p值；（3） $0.05 < p < 0.1$,就是10%置信水平，*； $0.01 < p < 0.05$,就是5%置信水平，**； $p < 0.01$,就是1%置信水平，***；

- 需要了解：
- 1、OLS的假设：
 - （1）X与u不相关， $\text{corr}(X,u)=0$;
 - （2）X和Y独立同分布；
 - （3）X、Y不能有较大奇异值。
- 2、虚拟变量
 - 为0和1的二值变量，例如班级规模大于等于20人的为0，小于20人为1。这种变量成为虚拟变量、哑变量或者指示变量。

$$D_i = \begin{cases} 1, & X < 20 \\ 0, & X \geq 20 \end{cases}$$

初识STATA

- 双击“stata”图标



- 点击“data editor”打开数据管理界面




Table 2: 输入数据

obs	testscr	str
1	690.8	17.889
2	661.2	21.5247
3	643.6	18.6713
⋮	⋮	⋮

- 1、当我们想更改变量名时，可以输入：
- **rename** var1 testscr
- 2、当我们想看看数据的时候，我们可以输入：
- **list** testscr str
- 3、我们看看统计描述：
- **sum** testscr str, **detail**

```
. sum testscr str,detail
```


testscr


Percentiles		Smallest		
1%	605.55	605.55		
5%	606.15	606.75		
10%	607.875	609	Obs	20
25%	614.2	612.5	Sum of Wgt.	20
50%	616.9		Mean	625.275
		Largest	Std. Dev.	21.29214
75%	630.575	643.6		
90%	654.45	647.7	Variance	453.3554
95%	676	661.2	Skewness	1.797063
99%	690.8	690.8	Kurtosis	5.649889

str

Percentiles		Smallest		
1%	16.5098	16.5098		
5%	16.74384	16.97787		
10%	17.16751	17.35714	Obs	20
25%	18.34955	17.88991	Sum of Wgt.	20
50%	19.97779		Mean	19.69612
		Largest	Std. Dev.	1.694211
75%	20.94706	21.23809		
90%	21.46546	21.40625	Variance	2.870351
95%	22.11434	21.52466	Skewness	-.328499
99%	22.70402	22.70402	Kurtosis	2.169139

- 看了统计量之后，我们还想看看散点图和拟合线：
- 散点图命令：
- **scatter** testscr str
- 散点图+拟合线命令：
- **twoway scatter** testscr str | **lfit** testscr str





- 最重要的是，我们要OLS估计结果。
- 回归命令：
- **reg** testscr str
- 另一种形式：
- **reg** testscr str, r

```
. reg testscr str
```

Source	SS	df	MS	Number of obs	=	20
				F(1, 18)	=	1.84
Model	799.805171	1	799.805171	Prob > F	=	0.1914
Residual	7813.94765	18	434.108203	R-squared	=	0.0929
				Adj R-squared	=	0.0425
Total	8613.75282	19	453.355412	Root MSE	=	20.835

testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
str	-3.829551	2.821335	-1.36	0.191	-9.756957	2.097855
_cons	700.7023	55.76432	12.57	0.000	583.5458	817.8588

. reg testscr str,r

Linear regression

Number of obs = 20
F(1, 18) = 1.47
Prob > F = 0.2404
R-squared = 0.0929
Root MSE = 20.835

testscr	Robust					
	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
str	-3.829551	3.154197	-1.21	0.240	-10.45627	2.79717
_cons	700.7023	63.98125	10.95	0.000	566.2827	835.1219

多元回归

- 在上述一元回归中，如果还有因素决定 Y ，且与 X 相关，那么，这个因素肯定包含在 u 中。此时就会产生“遗漏变量偏误”。
- 遗漏变量偏误可以说是我们写实证论文最要关注的问题：
- (1)无论样本大小，跑回归，首先要问是否有遗漏变量偏误；
- (2)遗漏变量偏误的大小依赖于 u 和 X 的相关系数，相关系数越大，偏误越大；
- (3)偏误的方向（高估or低估）依赖于 u 和 X 相关系数的符号，相关系数小于0，就引起低估；在实践中，低估还可以接受，一定要避免高估的问题。

- 我们首先想到的解决办法肯定是，遗漏什么就什么：

$$Y_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + u_i, \quad i = 1, \dots, n$$

. reg testscr str el_pct						
Source	SS	df	MS	Number of obs	=	420
Model	64864.3011	2	32432.1506	F(2, 417)	=	155.01
Residual	87245.2925	417	209.221325	Prob > F	=	0.0000
Total	152109.594	419	363.030056	R-squared	=	0.4264
				Adj R-squared	=	0.4237
				Root MSE	=	14.464
testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
str	-1.101296	.3802783	-2.90	0.004	-1.848797	-.3537945
el_pct	-.6497768	.0393425	-16.52	0.000	-.7271112	-.5724423
_cons	686.0322	7.411312	92.57	0.000	671.4641	700.6004

- 除了前面讲到的关注点之外，多元回归还要关注：
- (1) R^2 会随着解释变量的增加而变大；
- (2) F统计量；
- **特别提醒注意：**
- (3) R^2 的变大不能告诉我们任何有意义的经济答案，因此，不要太迷信它；
- (4) 一定要在因果关系中区分核心解释变量和控制变量。例如，班级规模是核心解释变量，其他都是控制变量。我们最关心核心解释变量的因果解释，而控制变量则无需任何因果解释，加入它们的作用在于降低遗漏变量偏误。

理论和实践中的模型设定

- 从理论来讲，如果遗漏变量数据可用，解决遗漏变量偏误，只需要在回归模型中加入遗漏变量即可。
- 从实践来看，应对遗漏变量偏误的方法：
- 基础解释变量集应用依靠专业判断、经济理论以及对数据的了解，并进行综合决策。包含基础解释变量的集合有时也称为基准模型。
- 第一步，基准模型应该包含主要的核心解释变量和控制变量，这些变量是根据专业判断和经济理论得到的。
- 第二步，有经济理论得到的变量经常没有可用的数据，那么，就需要提出许多备择模型设定，即一些备择的回归因子。

- 
- 如果在备择模型中，核心解释变量的数值与基准模型相似，这就说明基准模型的估计结果可信。
 - 另一方面，如果核心解释变量的估计结果在备择模型中变化较大，那么，这说明基准模型存在遗漏变量偏误。

1.3 经验研究评价

- 上面，我们得到了 $\beta_1 = -2.28$ ，那么，我们要相信这个结果吗？我们如何评价一个经验研究呢？
- 两个方面：
- 1、内部有效性
- 如果一个研究关于因果效应的统计推断对于所研究的总体和环境是有效的
- 2、外部有效性
- 如果这个研究的结论能推广至其他总体和环境

内部有效性的威胁

- 内部有效性包含两个方面的内容：
- (1)OLS估计量无偏和一致；
- (2)标准误得到的置信区间有合意的置信水平。
- 有偏的原因主要有五个方面：
- **(1)遗漏变量偏误**
- (2)回归函数误设
- **(3)变量的测量误差**
- **(4)样本选择偏误**
- **(5)双向因果**
- 出现这五个方面的问题都是因为总体回归方程中回归量与误差项相关，打破了OLS第一假设。

一、遗漏变量偏误

- 1、当变量可观测或有恰当控制的变量时，**遗漏变量偏误的解决办法：增加解释变量**
- **第一步**，识别出回归模型中感兴趣的系数和关键系数。例如，前面的例子中，关键系数是学生-老师比的系数。
- **第二步**，自问“我们的回归中，重要的遗漏变量偏误来源于什么？”这就需要我们应用经济理论和专业知识。这一步应该在回归之前就完成。这一步的回归应该当做基准回归模型，也就是经验回归分析的开始。
- **第三步**，扩展基准回归。如果加入的控制变量系数是统计显著的，或者如果加入遗漏变量后，感兴趣的变量系数估计量发生明显变化，那么，这些变量应该保留，反之亦然。
- **第四步**，把我们的回归结果详细的列示在图表中。这一步是为了方便别人查看，并发现一些可疑之处，进而提出一些有益的意见和建议。

- 2、当适当的控制变量不可用时，遗漏变量偏误的解决办法
- 第一种方法：面板数据模型，面板数据可以控制不可观测的遗漏变量，但是要求这些遗漏变量不随时间变化或不随个体变化。
- 第二种方法：工具变量法，这种方法依赖一个被称为工具变量的新变量。
- 第三种方法：随机控制实验——DID或者RD等。
- 第四种方法：时间差分 and 空间差分法（详见Duranton et al., 2009; Belotti et al., 2016）、时间趋势多项式法（包括时间趋势二次型）（参见Wolfers, 2006）、交互固定效应（参见Bai, 2009; Kim and Oka, 2014）。

二、测量误差

- 假如我们在测量或者录入数据时，不小心把自变量的数据搞错了，这也会导致OLS估计产生偏误。
- 解决方法：
 - 方法一：工具变量法，工具变量与 X 相关，但不与测量误差相关。
 - 方法二：提出一个测量误差的数学模型，如果可能用包含这个数学公式所表示的指标来调整估计量。最简单的方法就是利用一个更精确的 X 来重新回归。也就是通常，用多个表示 X 含义的变量来回归，并将结果进行比较。

三、缺失数据和样本选择

- 数据缺失是经济数据集的常见现象。数据缺失是否对内部有效性造成威胁取决于数据为什么缺失。考虑三种情形：
- 情形一：数据缺失完全是随机的。在这种情形下，随机缺失的原因与 X 或 Y 不相关，这只会导致样本规模变小（删除缺失样本），而不会导致估计偏误。
- 情形二：缺失数据依赖于 X 。在这种情形下，也只会导致样本规模变小，不会引起偏误。
- 情形三：由于样本选择过程造成的数据缺失，与 Y 相关。这种选择过程会引起误差项与回归量相关。这种OLS估计量偏误称为样本选择偏误。
- 解决方法：上面提到的那些方法都解决不了样本选择偏误。在实践中，常用的方法是改变样本，对多个样本进行回归，并比较回归结果。

四、双向因果或同时因果

- 两种方式解决：
- 第一，工具变量；
- 第二，随机控制实验—DID、RD、PSM、合成控制法



五、回归函数误设

- 不是线性模型
- 非线性模型

标准误不一致性来源

- 异方差：用异方差稳健标准误和异方差稳健方差估计量构建的F统计量来解决；
- 序列相关：使用稳健标准误来解决。

1.4 面板数据模型

- 影响经验研究内部有效性的几个方面：遗漏变量偏误、测量误差、样本选择问题、双向因果、模型设定问题、异方差和序列相关等。
- 前面，多元回归就是加入一些决定 Y ，且与 X 相关的解释变量 W 。但这要求 W 是可观测的。
- 对于那些决定 Y ，且与 X 相关，但又不可观测的因素，怎么办？

- 下面，我们来看看抑制“醉驾”的政策对交通事故死亡率
- 面板数据格式：

Data Editor (Edit) - [fatality.dta]

File Edit View Data Tools

unrate[6] 7.8000002

	state	year	spircons	unrate	perinc	emppop	beertax	sobapt	mormon	mlda	dry
1	AL	1982	1.37	14.4	10544.15	50.69204	1.539379	30.3557	.32829	19	25.0063
2	AL	1983	1.36	13.7	10732.8	52.14703	1.788991	30.3336	.34341	19	22.9942
3	AL	1984	1.32	11.1	11108.79	54.16809	1.714286	30.3115	.35924	19	24.0426
4	AL	1985	1.28	8.9	11332.63	55.27114	1.652542	30.2895	.37579	19.67	23.6339
5	AL	1986	1.23	9.8	11661.51	56.5145	1.609907	30.2674	.39311	21	23.4647
6	AL	1987	1.18	7.8	11944	57.50988	1.56	30.2453	.41123	21	23.7924
7	AL	1988	1.17	7.2	12368.62	56.83453	1.501444	30.2233	.43018	21	23.7924
8	AZ	1982	1.97	9.9	12309.07	56.8933	.2147971	3.9589	4.9191	19	0
9	AZ	1983	1.9	9.1	12693.81	57.55363	.206422	3.8901	4.83107	19	0
10	AZ	1984	2.14	5	13265.93	60.37902	.2967033	3.8226	4.74461	19	0
11	AZ	1985	1.86	6.5	13726.7	58.64853	.3813559	3.7562	4.65971	21	0
12	AZ	1986	1.78	6.9	14107.33	60.28018	.371517	3.691	4.57632	21	0
13	AZ	1987	1.72	6.2	14241	60.21506	.36	3.6269	4.49442	21	0
14	AZ	1988	1.68	6.3	14408.08	60.49767	.346487	3.564	4.41399	21	0
15	AR	1982	1.19	9.8	10267.3	54.47586	.650358	22.9672	.32829	21	36.7128
16	AR	1983	1.2	10.1	10433.49	53.81479	.6754587	23.0009	.34341	21	36.4301

Data Editor (Edit) - [fatality.dta]


File Edit View Data Tools

spircons[1]


缺失值

	state	year	spircons	unrate	perinc	emppop	beertax	sobapt	mormon	mla
1	AL	1982		14.4	10544.15	50.69204	1.539379	30.3557	.32829	19
2	AL	1983	1.08	13.7	10732.8	52.14703	1.788991	30.3336	.34341	19
3	AL	1984	1.32	11.1	11108.79	54.16809	1.714286	30.3115	.35924	19
4	AL	1985	1.28	8.9	11332.63	55.27114	1.652542	30.2895	.37579	19.67
5	AL	1986	1.23	9.8	11661.51	56.5145	1.609907	30.2674	.39311	21
6	AL	1987	1.18	7.8	11944	57.50988	1.56	30.2453	.41123	21
7	AL	1988	1.17	7.2	12368.62	56.83453	1.501444	30.2233	.43018	21
8	AZ	1982	1.97	9.9	12309.07	56.8933	.2147971	3.9589	4.9191	19
9	AZ	1983	1.9	9.1	12693.81	57.55363	.206422	3.8901	4.83107	19
10	AZ	1984	2.14	5	13265.93	60.37902	.2967033	3.8226	4.74461	19
11	AZ	1985	1.86	6.5	13726.7	58.64853	.3813559	3.7562	4.65971	21
12	AZ	1986	1.78	6.9	14107.33	60.28018	.371517	3.691	4.57632	21
13	AZ	1987	1.72	6.2	14241	60.21506	.36	3.6269	4.49442	21
14	AZ	1988	1.68	6.3	14408.08	60.49767	.346487	3.564	4.41399	21
15	AR	1982	1.19	9.8	10267.3	54.47586	.650358	22.9672	.32829	21
16	AR	1983	1.2	10.1	10433.49	53.81479	.6754587	23.0009	.34341	21
17	AR	1984	1.22	8.9	10916.48	54.67128	.5989011	23.0346	.35924	21
18	AR	1985	1.12	8.7	11149.36	54.97712	.5773305	23.0684	.37579	21
19	AR	1986	.92	8.7	11399.38	55.56186	.5624355	23.1022	.39311	21
20	AR	1987	1.01	8.1	11537	56.33089	.545	23.1361	.41123	21
21	AR	1988	.99	7.7	11760.35	57.36695	.5245429	23.17	.43018	21

- 
- 政策变量：酒精税(BeerTax)
 - 死亡率：vfrall
 - 美国48个州
 - 时间：1982-1988年
 - 截面数据（1982年）散点图和拟合线：



- 1988年散点图和拟合线：



- 
- 从上面两幅散点图直观看出：酒精税越高，死亡率越高。
 - 这不对呀！
 - 我们首先想到的是，这样回归可能遗漏了一些决定死亡率，且与酒精税相关的因素。这会引起**遗漏变量偏误**。
 - 那么，自然的解决办法就是将这些因素加入回归方程中。
 - 这要求加入的遗漏变量可观测。
 - 但，如汽车质量；公路质量；在农村开车还是在城市；道路上车流密度；对待饮酒和开车的态度等等不可观测的因素有遗漏呢？

- 如果这些不可观测的遗漏变量不随时间或个体变化，那么，我们可以使用另一种方法来降低遗漏变量偏误——固定效应模型。
- 固定效应模型对数据的要求是每个个体至少要有两期及以上的数据——面板数据。
- 将1982年和1988年结合在一起。

$$vfrall_{it} = \beta_0 + \beta_1 BeerTax_{it} + \beta_2 Z_i + u_{it}$$

- 其中， $i=48$ ， $t=2$ ； Z_i 就是不随时间变化的不可观测因素。


$$vfrall_{i1982} = \beta_0 + \beta_1 BeerTax_{i1982} + \beta_2 Z_i + u_{i1982}$$

$$vfrall_{i1988} = \beta_0 + \beta_1 BeerTax_{i1988} + \beta_2 Z_i + u_{i1988}$$

- 将两式相减：

$$vfrall_{i1988} - vfrall_{i1982} = \beta_1 (BeerTax_{i1988} - BeerTax_{i1982}) + (u_{i1988} - u_{i1982})$$

- 通过分析被解释变量Y与解释变量X的 **变化量** 可以消除不随时间变化的不可观测因素，从而消除这种来源的遗漏变量偏误。



- 我们上面有7年的数据：1982-1988

$$Y_{it} = \beta_0 + \beta_1 X_{it} + \beta_2 Z_i + u_{it}$$

- 其中， $i=48$ ， $t=7$ ；令 $\alpha_i = \beta_0 + \beta_2 Z_i$
- 上式变为：

$$Y_{it} = \beta_1 X_{it} + \alpha_i + u_{it}$$

- 上式就是**固定效应模型**。需要注意的是，上述总体回归线的斜率对于每个州都是相同的，但是每个州又对应着不同的截距。因为 α_i 考虑的是个体 i 的效应，因此，它也被称为**个体固定效应**。

- 固定效应模型的另一种表达式：

$$Y_{it} = \beta_0 + \beta_1 X_{it} + \gamma_2 D_{2i} + \cdots + \gamma_n D_{ni} + u_{it}$$

- 引入地区虚拟变量。这种表达式与前一页的表达式是等价的。
- 从一开始，我们最关心的就是 β_1 ，那么，我们如何估计它呢？
- 因为固定效应模型中包含不可观测因素 α ，因此，不能直接用OLS；而虚拟变量形式中，如果个体数量很大，我们不可能在stata中输入所有的个体虚拟变量。那我们怎么办？

- 最直接的办法就是在stata中输入命令
- **xtreg** vfrall BeerTax, **fe**

```
. xtreg vfrall beertax, fe
```

```
Fixed-effects (within) regression           Number of obs   =       336
Group variable: state                      Number of groups =       48

R-sq:                                     Obs per group:
    within = 0.0407                        min =           7
    between = 0.1101                       avg =          7.0
    overall = 0.0934                       max =           7

corr(u_i, Xb) = -0.6885                    F(1,287)         =      12.19
                                           Prob > F         =      0.0006
```

vfrall	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
beertax	-.6558736	.18785	-3.49	0.001	-1.025612	-.2861352
_cons	2.377075	.0969699	24.51	0.000	2.186212	2.567937
sigma_u	.7147146					
sigma_e	.18985942					
rho	.93408484	(fraction of variance due to u_i)				

F test that all u_i=0: F(47, 287) = 52.18

Prob > F = 0.0000

- 但是，如果我只讲到这里，那大家花钱来听这个就太不值得了。
- 知其然，也要知其所以然！
- 那么，stata的里面的算法是什么呢？去均值算法-两步：
- 第一步，每个变量减去其个体层面的均值。 $Y_{it} - \bar{Y}_i$
$$\tilde{Y}_{it} = \beta_1 \tilde{X}_{it} + \tilde{u}_{it}$$
- 第二步，OLS估计上述去均值回归方程。

- 还有一种不可观测因素，随时间变化不随个体变化

$$Y_{it} = \beta_0 + \beta_1 X_{it} + \beta_3 S_t + u_{it}$$

$$\lambda_t = \beta_0 + \beta_3 S_t$$

$$Y_{it} = \beta_1 X_{it} + \lambda_t + u_{it}$$

- 时间固定效应模型。
- 它也有虚拟变量形式，设置时间虚拟变量。
- 算法同个体固定效应。

- 实践中，我们更常见的是：双向固定效应——个体和时间固定效应。

$$Y_{it} = \beta_1 X_{it} + \alpha_i + \lambda_t + u_{it}$$

- 算法：
- 第一步，个体去均值；
- 第二步，时间去均值；
- 第三步，OLS估计两次去均值之后的回归方程。
- 另一种方式，就是我们常用的Y和X只减去个体层面的均值，然后设立时间虚拟变量，用fe命令进行回归。

- **特别注意注:**
- (1)一般来讲，面板数据都需要控制个体固定效应和时间固定效应，因为这可以消除不可观测的随时间可变不随个体变化的因素和不随个体变化随时间变化的因素所引起的遗漏变量偏误。在使用家庭（企业）层面、省（市县）层面的数据后，还要同时控制家庭固定效应、省固定效应和时间固定效应。
- (2)在面板数据回归中，一定要使用“聚类标准误”，也就是个体层面的聚类。

交通死亡率

- 首先我们看看变量统计特征
- **sum**

Variable	Obs	Mean	Std. Dev.	Min	Max
state	336	30.1875	15.30985	1	56
year	336	1985	2.002983	1982	1988
spircons	336	1.75369	.6835745	.79	4.9
unrate	336	7.346726	2.533405	2.4	18
perinc	336	13880.18	2253.046	9513.762	22193.46
emppop	336	60.80568	4.721656	42.9932	71.26865
beertax	336	.513256	.4778442	.0433109	2.720764
sobapt	336	7.156925	9.762621	0	30.3557
mormon	336	2.801933	9.665279	.1	65.9165
mlda	336	20.45563	.8990255	18	21
dry	336	4.267074	9.500901	0	45.7921
yngrdrv	336	.1859299	.0248736	.073137	.281625
vmiles	336	7890.754	1475.659	4576.346	26148.27
breath	336	.4613095	.4992443	0	1
jaild	335	.280597	.449963	0	1
comserd	335	.1850746	.388939	0	1
allmort	336	928.6637	934.0515	79	5504
mrall	336	.000204	.000057	.0000821	.0004218
allnite	336	182.5833	188.4311	13	1049

- 
- 生成新的变量:
 - `gen y82=(year==1982);`
 - `gen y83=(year==1983);`
 - `gen y84=(year==1984);`
 - `gen y85=(year==1985);`
 - `gen y86=(year==1986);`
 - `gen y87=(year==1987);`
 - `gen y88=(year==1988);`
 - `gen da18=(mlda<19`
 - `gen da19=(mlda>=19)*(mlda<20);`

- 
- `gen da20=(mlda>=20)*(mlda<21);`
 - `gen da21=(mlda>=21);`
 - `gen vfrall=10000*mrall;`
 - `gen incperc=perinc/1000;`
 - `gen lincperc = ln(incperc);`
 - `gen vmilespd = vmiles/1000;`
 - `gen frmall = mrall/(vmiles/100000);`
 - `gen jailcom = ((jaild+comserd)>0);`
 - `gen mjailcom = (jaild==.)*(comserd==.);`
 - `mvdecode mjailcom,mv(1);`
 - `replace jailcom = jailcom + mjailcom;`

- 首先，要告诉stata我们用的是面板数据：
- `xtset state year`; *声明面板数据类型

```
. xtset state year
      panel variable:  state (strongly balanced)
      time variable:  year, 1982 to 1988
                delta:  1 unit
```

- Run 个体固定效应模型
- `xtreg vfrall beertax, fe vce(cluster state)`

```
. xtreg vfrall beertax, fe vce(cluster state)
```

```
Fixed-effects (within) regression      Number of obs   =       336
Group variable: state                  Number of groups =       48
```

```
R-sq:                                Obs per group:
    within = 0.0407                      min =          7
    between = 0.1101                     avg =         7.0
    overall = 0.0934                      max =          7
```

```
corr(u_i, Xb) = -0.6885                F(1,47)         =       5.05
                                          Prob > F        =       0.0294
```

(Std. Err. adjusted for 48 clusters in state)

vfrall	Robust		t	P> t	[95% Conf. Interval]	
	Coef.	Std. Err.				
beertax	-.6558736	.2918556	-2.25	0.029	-1.243011	-.0687358
_cons	2.377075	.1497966	15.87	0.000	2.075723	2.678427
sigma_u	.7147146					
sigma_e	.18985942					
rho	.93408484	(fraction of variance due to u_i)				

- 双向固定效应
- **xtreg** vfrall beertax y82 y83 y84 y85 y86 y87, **fe**
vce(cluster state)

```
. xtreg vfrall beertax y82 y83 y84 y85 y86 y87, fe vce(cluster state)
```

Fixed-effects (within) regression	Number of obs	=	336
Group variable: state	Number of groups	=	48
R-sq:	Obs per group:		
within = 0.0803	min =		7
between = 0.1101	avg =		7.0
overall = 0.0876	max =		7
	F(7,47)	=	4.36
corr(u_i, Xb) = -0.6781	Prob > F	=	0.0009


(Std. Err. adjusted for 48 clusters in state)

vfrall	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
beertax	-.6399799	.3570783	-1.79	0.080	-1.358329	.0783691
y82	.0518038	.0644023	0.80	0.425	-.0777568	.1813645
y83	-.0280991	.0528959	-0.53	0.598	-.1345119	.0783138
y84	-.0206167	.0398023	-0.52	0.607	-.1006887	.0594552
y85	-.0721725	.0376438	-1.92	0.061	-.1479021	.0035572
y86	.0139393	.0287262	0.49	0.630	-.0438503	.071729
y87	.0009018	.0287037	0.03	0.975	-.0568427	.0586462
_cons	2.376666	.1673381	14.20	0.000	2.040025	2.713307

第二讲 工具变量法

- 再次强调：经验研究内部有效性的威胁：遗漏变量偏误、测量误差、双向因果、样本选择、模型设定。
- 多元回归、固定效应模型降低某些遗漏变量偏误。
- 相当于引入 $(Z_{it}, \alpha_i, \gamma_t)$
- 一来，除了引入其他变量之外，还有没有其他方法来消除遗漏变量偏误；
- 二来，除了遗漏变量偏误之外，测量误差和双向因果问题如何解决呢？
- 当然有：工具变量法（IV）

- 遗漏变量偏误是由于 X 与 u 相关了
- IV的核心思想：分解 X
- (1) X 的一部分与 u 相关；
- (2) X 的另一部分与 u 不相关。



- 我们用以分离出 X 与 u 无关部分的变量就称为IV。
- 如字面意思，这些变量被作为工具来分离出 X 中与 u 无关的部分，从而确保回归系数估计量具有一致性。

一、一元回归与单IV

- 一元回归

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

- 我们还是最关心的 β_1 。但是现在 X 与 u 相关了，我们不能得到有效的 β_1 。
- 根据上面的IV核心思想，我们现在的任务就是要找到一个工具变量 I 来分离 X ，找到 X 与 u 无关的部分。
- 那么，怎么找呢？我们先卖个关子！

- 有效的工具变量必须同时满足两个条件：

(1) 工具变量相关性条件： $\text{corr}(I_i, X_i) \neq 0$

(2) 工具变量外生性条件： $\text{corr}(I_i, u_i) = 0$

- 工具变量相关性表明一个工具变量的变动与X的变动相关。工具变量外生性表明工具变量抓住了X中外生变化的部分。**注意：这两个条件对于工具变量回归非常重要。**
- 那么，怎么检验这两个假设，也就是怎么检验我们找到的工具变量是否有效呢？我们再卖个关子！

- 我们先来看看，我们最关心的问题，如何把 β_1 估计出来
- 估计IV估计量的方法叫做“**二阶段最小二乘 (TSLS)**”
- 顾名思义，分两个阶段用最小二乘呗：
- **第一阶段，用我们找到的工具变量 l ，分离出 X 中与 u 无关的部分；**具体做法是，

$$X_i = \pi_0 + \pi_1 I_i + v_i$$

- 这个时候，我们就把 X 分解成 $\pi_0 + \pi_1 I_i$ 和 v_i ；然后，我们估计出 π ，计算出 X 的估计值 $\hat{X}_i = \hat{\pi}_0 + \hat{\pi}_1 I_i$ （这个值很重要）。

- 第二阶段，我们利用估计出来的 $\hat{x}_i$ 作为原始回归中的解释变量，与Y进行回归，从而估计出 β_1 。
- 下面，我们用销售税作为工具变量，来考察香烟的价格需求弹性。
- 我们使用的是一个面板数据，个体是48个州，时间是1985-1995年。

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

- Y是香烟消费量对数；X是香烟税后价格对数；我们要估计 β_1

- 假设我们现在有个初步的工具变量——销售税(SaleTax)
- 我们首先应该根据我们的理论储备、经验等等初略判断一下销售税是否满足IV的两个假设：
- **首先，工具变量相关性。**销售税越高，香烟的税后价格也会越高，那么，销售税与香烟价格具有相关性；
- **其次，工具变量外生性。**一般来说，销售税在各州之间是不同的，但是这种差异并不主要由香烟需求决定，而是由于政治考虑。因此，我们也可以认为销售税是外生的。

- TSLS:
- 第一阶段，用销售税与香烟价格对数进行回归：

$$\ln(\tilde{P}_i^{cig}) = 4.62 + 0.31SalesTax_i$$

- 第二阶段，用估计的 $\ln(\tilde{P}_i^{cig})$ 作为解释变量，来回归：

$$\ln(\tilde{Q}_i^{cig}) = 9.72 - 1.08\ln(\tilde{P}_i^{cig})$$

- 实践中，在IV回归中，有四种变量：被解释变量 Y ；内生解释变量 X ；外生解释变量 W ；工具变量 I 。
- 一般来说，可能存在多个内生解释变量，多个外生解释变量和多个工具变量。
- 回归系数是恰好识别，如果工具变量与内生解释变量一样多；
- 回归系数是过度识别，如果工具变量比内生解释变量还多；
- 回归系数是识别不足，如果工具变量比内生解释变量还少；
- **需要注意的是：**IV回归中，至少要有与内生解释变量一样多的工具变量。

小贴士：关于W的选择

- 控制变量一般没有因果解释，但控制变量又很重要，那么，如何选择控制变量呢？一般来说我们只需控制能够同时影响解释变量和被解释变量的变量（**confounder**）。但是，我们在投稿时经常会收到审稿人的意见，说这个没有控制那个也没有控制。或者自己有意无意的在回归中包含了过多的控制变量。而控制变量过多往往会造成模型损失自由度，模型不够简洁，模型过度拟合，甚至我们会得出错误的结论。这些问题在小样本回归中尤为严重。因此，我们在回归时，真正要考虑的是，什么样的变量不需要被控制？

- 根据某一备选变量在因果关系中的位置，可以分以下几种情况讨论：
- （1）既不影响解释变量，也不影响被解释变量。很多社会经济变量仅仅因为常见，而被人们要求加入模型。但如果没有可信的理论来支撑对解释变量和被解释变量的影响的话，不应将其纳入模型；
- （2）只影响解释变量的变量。这类变量与关键解释变量没有直接影响，不影响我们对解释变量影响的估计，当然无需纳入模型中控制；
- （3）只影响被解释变量的变量。这类变量与关键解释变量不存在理论上的相关性，不会造成遗漏变量偏误，无需控制；

- （4）被解释变量影响，又影响解释变量的变量，即中介变量（**mediator**）。考虑到我们的关键解释变量对被解释变量的影响往往是通过一个或多个渠道（因果链条可无限细分），这时就要分两种情况做决定：如果该中介变量处在我们假设的因果链条中，那就应该将其去掉，因为加入这个变量会让解释变量的影响从全部影响减弱为直接影响，而间接影响则被中介变量吸收，从而削弱了我们对解释变量整体效应的估计；如果该中介变量并不处在我们假设的因果链条中，那就应该保留，这时对自变量影响的估计就会自动排除竞争性解释的影响，有助于提高估计结果的可信度；
- （5）当然，有时候，会遇到审稿人搞不清因果关系，坚持要求加入某个变量来控制。考虑到硬怼审稿人没什么好下场，因此建议，审稿人说什么就是什么，听从他们的意见，控制审稿意见要求的变量。

- 加入控制变量W的IV回归

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 W_{1i} + \cdots + \beta_{1+r} W_{ri} + u_i$$

- 此时，我们还是关心 β_1 。还是使用TSLS估计。
- *第一阶段，*

$$X_i = \pi_0 + \pi_1 I_{1i} + \cdots + \pi_m I_{mi} + \pi_{m+1} W_{1i} + \cdots + \pi_{m+r} W_{ri} + v_i$$

- *第二阶段，用估计的X来与Y回归，得到 β_1 。*

小贴士

- 1、在进行第一阶段回归时，除了工具变量外，所有的外生变量（或控制变量）都需要包含在其中。而第二阶段回归也需要包含这些外生变量。
- 2、当有多个内生解释变量时，第一阶段的工具变量回归是每个内生解释变量分别与它对应的工具变量进行回归，然后再将所有的估计值放入第二阶段回归中得到**TSLS**估计量。

- 香烟弹性：
- 州的收入水平也可能会影响香烟需求量，也可能影响销售税和销售价格。那么，我们要控制州的收入。

$$\ln(\tilde{Q}_i^{cig}) = 9.43 - 1.14\ln(P_i^{cig}) + 0.21\ln(Inc_i)$$

- 第二种可能的IV：烟草特种税（**CigTax**）提高会增加香烟的价格，因此满足相关性条件，如果它与误差项无关，那么它也满足外生性条件。

$$\ln(\tilde{Q}_i^{cig}) = 9.89 - 1.28\ln(P_i^{cig}) + 0.28\ln(Inc_i)$$

IV有效性检验

- 那么，上述IV估计结果可信吗？很遗憾，我们不能立马回答上述问题，因为可信度依赖于IV是否有效。因此，IV有效的两个条件——相关性和外生性就必须要被检验。
- 香烟需求价格弹性：

Dependent variable: $\ln(Q_{i,1995}^{cigarettes}) - \ln(Q_{i,1985}^{cigarettes})$

Regressor	(1)	(2)	(3)
$\ln(P_{i,1995}^{cigarettes}) - \ln(P_{i,1985}^{cigarettes})$	-0.94** (0.21)	-1.34** (0.23)	-1.20** (0.20)
$\ln(Inc_{i,1995}) - \ln(Inc_{i,1985})$	0.53 (0.34)	0.43 (0.30)	0.46 (0.31)
Intercept	-0.12 (0.07)	-0.02 (0.07)	-0.05 (0.06)
Instrumental variable(s)	Sales tax	Cigarette-specific tax	Both sales tax and cigarette-specific tax
First-stage F -statistic	33.70	107.20	88.60
Overidentifying restrictions J -test and p -value	—	—	4.93 (0.026)

These regressions were estimated using data for 48 U.S. states (48 observations on the 10-year differences). The data are described in Appendix 12.1. The J -test of overidentifying restrictions is described in Key Concept 12.6 (its p -value is given in parentheses), and the first-stage F -statistic is described in Key Concept 12.5. Individual coefficients are statistically significant at the *5% significance level or **1% significance level.

相关性

外生性

检验IV的相关性

- 工具变量相关性的作用类似于“样本规模的作用”。因为工具变量与内生解释变量越相关，说明IV回归中包含X的信息越多，TOLS估计量越准确，这就类似与样本量越大，估计结果越准确。
- 工具变量解释X变动的部分较少时，这种工具变量成为弱工具变量。
- 那么，如何检验一个工具变量是否是弱工具变量？如果是弱工具变量，我们应该怎么处理？
- 这些问题涉及到渐近分布，十分复杂。

- 幸好我们有一些检验弱工具变量的经验规则：
- 当只有一个内生解释变量时，检验弱工具变量的方法就是计算TSLS第一阶段的F统计量。第一阶段F统计量为包含在工具变量中的信息提供了一个不错的测量指标：包含的信息越多，F统计量越大。
- 经验规则是：如果第一阶段F统计量大于**10**，不存在弱工具变量；如果小于**10**，可能就是弱工具变量。
- 但如果存在弱工具变量，我们该怎么办呢？

- 如果存在弱工具变量，且有一些工具变量比另一些更弱。那么，就应该舍弃那些最弱的工具变量。当我们放弃一些弱工具变量时，**TSLS**估计量的标准误可能会变大，但是**请记住“原始标准误没有任何意义”！**
- 但是，如果系数恰好识别，也就是一个内生解释变量，只有一个工具变量，且是弱工具变量时，我们就不能舍弃这个弱工具变量了。即使在过度识别时，没有足够的强工具变量来取得识别效果，舍弃弱工具变量也不会有任何帮助。这种情况下，我们可以干两件事：
- **（1）去寻找其他的更强的工具变量。**说起来容易，做起来难！这需要我们对所研究的问题有足够的认识，并且能重写设计和收集相关数据。
- **（2）仍然使用弱工具变量，但是估计方法不用TSLS，而用其他估计方法，例如有限信息极大似然（LIML）估计量。**

IV的外生性检验

- 首先要知道的是：**IV**的外生性检验只能用于过度识别情形。
- 在过度识别情形下，我们有一个统计量——***J*统计量**来检验**IV**的外生性。其核心思想：
- 如果有一个内生解释变量，多个工具变量，那么，我们可以计算出多个**TSLS**估计量（每个工具变量计算一个）。
- 假设有两个工具变量，那么，我们计算的两个**TSLS**估计量不同。但是如果两个工具变量都是外生的，那么，它们会十分接近。
- 如果我们估计的两个**TSLS**估计量差异非常大，那么，我们就要非常警觉：要么其中一个工具变量不是外生的，要么两个都不是外生的。

- 总之，在过度识别情形下，我们能计算出多个TSLS估计量，然后比较它们是否接近，即通过stata计算出**J统计量**。如果是精确识别情形，我们就不能比较，实际上，这个时候的J统计量为0。
- J统计量显著，意味着IV不是外生的。是否就意味着我们估计的三个结果都不行呢？这个时候，我们就要做**推断**。
- **千万要记住：**统计证据并不能告诉我们哪一种可能是正确的，因此这就需要我们根据我们的经验以及经济理论去argue。

哪里去寻找有效的工具变量呢？

- 在实践中，IV回归最难的就是找到有效的工具变量。虽然如此，但是还是有两种指导性的方法：
- （I）遵循经济理论来找工具变量。但是经济理论太抽象，并不总是能找到一个有效的IV。
- （II）构造工具变量。从这种视角出发，我们要去寻找那些引起内生解释变量变化的随机事件，从这些随机事件中剥离出X变动的外生冲击。

香烟需求弹性stata操作

- 生成新变量
- `gen ravgprs = avgprs/cpi;`
- `label var ravgpr "real average price during fiscal year, including sales taxes";`
- `gen rtax = tax/cpi;`
- `label var rtax "real average Cig specifice tax during fiscal year";`
- `gen rtaxs = taxes/cpi;`
- `label var rtaxs "real average total tax during fiscal year,including sales taxes";`
- `gen rtaxso = rtaxs-rtax;`
- `label var rtaxso "real average sales tax per pack during fiscal year";`
- `gen lpackpc = log(packpc);`
- `gen lravgprs = log(ravgprs);`

- 
- `gen perinc = income/(pop*cpi);`
 - `gen lperinc = log(perinc);`
 - `encode state, gen(snum);`
 - `gen ltpackpc = log(packpc/packpc[_n-1]);`
 - `gen ltavgprs = log(ravgprs/ravgprs[_n-1]);`
 - `gen ltperinc = log(perinc/perinc[_n-1]);`
 - `gen dtrtaxs = rtaxs-rtaxs[_n-1];`
 - `gen dtrtax = rtax-rtax[_n-1];`
 - `gen dtrtaxso = rtaxso-rtaxso[_n-1];`
 - `keep if year==1995;`

- 首先是第一阶段回归:
- `reg lavgprs rtaxso, r`

```
. reg lavgprs rtaxso, r
```

Linear regression

```
Number of obs   =          48
F(1, 46)        =         40.39
Prob > F         =         0.0000
R-squared        =         0.4710
Root MSE        =         .09394
```

lavgprs	Robust					
	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
rtaxso	.0307289	.0048354	6.35	0.000	.0209956	.0404621
_cons	4.616546	.0289177	159.64	0.000	4.558338	4.674755

- 第二阶段回归
- `reg lpackpc lravgprs, r`

```
. reg lpackpc lravgprs, r
```

Linear regression

```
Number of obs   =          48
F(1, 46)        =        38.86
Prob > F         =        0.0000
R-squared        =        0.4058
Root MSE        =        .18962
```

lpackpc	Robust		t	P> t	[95% Conf. Interval]	
	Coef.	Std. Err.				
lravgprs	-1.213057	.1945897	-6.23	0.000	-1.604746	-.8213686
_cons	10.33892	.9348204	11.06	0.000	8.457229	12.22062

- Stata里直接有IV回归命令:
- **ivreg** lpackpc (lavgprs = rtaxso), r

```
. ivreg lpackpc (lavgprs = rtaxso), r
```

```
Instrumental variables (2SLS) regression      Number of obs      =           48
                                              F(1, 46)           =          11.54
                                              Prob > F            =           0.0014
                                              R-squared           =           0.4011
                                              Root MSE           =           .19035
```

lpackpc	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
lavgprs	-1.083587	.3189183	-3.40	0.001	-1.725536	-.4416373
_cons	9.719876	1.528322	6.36	0.000	6.643525	12.79623

```
Instrumented:  lavgprs
```

```
Instruments:   rtaxso
```

- 下面，我们看看加入控制变量的回归结果
- `ivreg lpackpc (lavgprs = rtaxso) lperinc, r`

```
. ivreg lpackpc (lavgprs = rtaxso) lperinc, r
```

Instrumental variables (2SLS) regression	Number of obs	=	48
	F(2, 45)	=	8.19
	Prob > F	=	0.0009
	R-squared	=	0.4189
	Root MSE	=	.18957

	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
lpackpc					
lavgprs	-1.143375	.3723025	-3.07	0.004	-1.893231 - .3935191
lperinc	.214515	.3117467	0.69	0.495	-.413375 .842405
_cons	9.430658	1.259392	7.49	0.000	6.894112 11.9672

Instrumented: 1ravgprs

Instruments: lperinc rtaxso

- 两个工具变量的回归
- **ivreg** lpackpc (lavgprs = rtaxso rtaxs) lperinc, r

```
. ivreg lpackpc (lavgprs = rtaxso rtaxs) lperinc, r
```

```
Instrumental variables (2SLS) regression      Number of obs      =           48
                                              F(2, 45)           =          16.17
                                              Prob > F            =           0.0000
                                              R-squared           =           0.4294
                                              Root MSE            =           .18786
```

lpackpc	Robust					
	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
lavgprs	-1.277424	.2496099	-5.12	0.000	-1.780164	-.7746837
lperinc	.2804045	.2538894	1.10	0.275	-.230955	.7917641
_cons	9.894955	.9592169	10.32	0.000	7.962993	11.82692

```
Instrumented:  lavgprs
```

```
Instruments:   lperinc rtaxso rtaxs
```

- 下面看看面板数据的IV回归
- `reg ltpackpc ltavgprs ltperinc, r`（普通OLS）
- 香烟销售税作为IV：
- `ivreg ltpackpc (ltavgprs = dtrtaxso) ltperinc, r`
- 一阶段回归：
- `reg ltavgprs dtrtaxso ltperinc, r`
- 相关性检验F统计量：
- `test dtrtaxso`

```
. test dtrtaxso
```

```
( 1) dtrtaxso = 0
```

```
F( 1, 45) = 47.26  
Prob > F = 0.0000
```

- 销售税作为IV:
- `ivreg ltpackpc (ltavgprs = dtrtax) ltperinc, r`
- 一阶段回归:
- `reg ltavgprs dtrtax ltperinc, r`
- 相关性检验F统计量:
- `test dtrtax`

```
. test dtrtax
```

```
( 1) dtrtax = 0
```

```
F( 1, 45) = 282.19  
Prob > F = 0.0000
```

- 两个IV:
- ivreg ltpackpc (ltavgprs = dtrtax dtrtaxso) ltperinc, r
- 计算出残差
- predict e, resid
- 工具变量对残差做回归
- reg e dtrtaxso dtrtax ltperinc
- 检验系数差异
- qui test dtrtaxso dtrtax
- 显示J统计量
- dis "---- OverID stat: " r(df)*r(F) _skip(10) "p-value: " chiprob(r(df)-1,r(df)*r(F)) " ----"

```
. dis "---- OverID stat: " r(df)*r(F) _skip(10) "p-value: " chiprob(r(df)-1,r(df)*r(F)) " ----"
```

```
---- OverID stat: 1.7430639 p-value: .18675108 ----
```

J统计量

P值

最新IV命令

- Chernozhukov等2018年1月18日发布了一个最新的IV命令——**cqiv**
- 删截和内生性会使得均值回归和分位数回归结果不一致。那么，怎么办呢？
- CQIV估计量用Powell（1986）提出的删截分位数回归（CQR）方法来解决删截问题，同时它用控制函数法来解决内生性问题。CQIV估计量采用了Chernozhukov and Hong（2002）对CQR的算法。

- 语法结构:
- `cqiv depvar [varlist] (endogvar = instrument) [if] [in] [weight]
[, quantiles(numlist) censorpt(#) top uncensored exogenous
firststage(string) exclude nquant(#) nthresh(#) ldv1(string)
ldv2(string) corner drop1(#) drop2(#) viewlog
confidence(string) bootreps(#) setseed(#) level(#) norobust]`
- **cqiv** 执行**CQIV**估计。有无删节、有无内生性都可以使用。
。注意，小括号里的所有变量都应该包含在**CQIV**和**QIV**第一阶段估计中

- 我们使用CFK（2015）的酒类恩格尔曲线的例子：
alcohol表示酒类消费份额，logexp支出，nkid孩子数量（控制变量），对于内生支出，使用可支配收入，例如logwages工资来作为工具变量。
- 首先，查看这个命令：
- ***ssc describe cqiv***

. ssc describe cqiv

package cqiv from <http://fmwww.bc.edu/repec/bocode/c>

TITLE

'CQIV': module to perform censored quantile instrumental variables regression

DESCRIPTION/AUTHOR(S)

cqiv conducts censored quantile instrumental variable (CQIV) estimation. This command can implement both censored and uncensored quantile IV estimation either under exogeneity or endogeneity. The estimator proposed by Chernozhukov, Fernandez-Val and Kowalski (2010) is used if CQIV estimation is implemented. A parametric version of the estimator proposed by Lee (2007) is used if quantile IV estimation without censoring is implemented. The estimator proposed by Chernozhukov and Hong (2002) is used if censored quantile regression (CQR) is estimated without endogeneity. Note that all the variables in the parentheses of the syntax are those involved in the first stage estimation of CQIV and QIV.

KW: quantile regression

KW: censored quantiles

- 第二步， 下载命令：
- ***ssc install cqiv, replace***

```
. ssc install cqiv,replace  
checking cqiv consistency and verifying not already installed..  
installing into c:\ado\plus\...  
installation complete.
```

- 第三步， 下载数据：
- ***net get cqiv***
-
- 第四步， 估计结果
- ***cqiv alcohol logexp2 nkids (logexp = logwages nkids), quantiles(25 50 75)***

```
. cqiv alcohol logexp2 nkids (logexp = logwages nkids), quantiles(25 50 75)
(fitting base model)
```

```
Censored quantile IV regression                                Number of obs =      1655
Censoring point =      0
Endogenous variable = logexp
Instrument(s) = logwages nkids
First stage estimation = quantile regression
No confidence intervals
```

alcohol	25	50	75
logexp			
_b	.3216247	.2463935	.0946595
mean	.	.	.
lower	.	.	.
upper	.	.	.
logexp2			
_b	-.0282586	-.0213251	-.0087811
mean	.	.	.
lower	.	.	.
upper	.	.	.
nkids			

- 此外，还可以用**cqiv**估计没有删截的分位数iv回归
- *cqiv alcohol logexp2 nkids (logexp = logwages nkids), quantiles(25 50 75)*
-
- 还有没有内生性的**CQR**估计
- *cqiv alcohol logexp logexp2 nkids, exogenous*

- 其他一些命令
- *cqiv alcohol logexp2 (logexp = logwages), quantiles(20 25 70(5)90) firststage(ols)*
- *cqiv alcohol logexp2 (logexp = logwages), firststage(distribution) ldv1(logit) exclude*
- *cqiv alcohol logexp2 nkids (logexp = logwages nkids), confidence(weightboot) bootreps(10)*
- *cqiv alcohol nkids (logexp = logwages nkids), corner*

计量论文黑客教程

- 到此，我们似乎就可以写出一篇计量论文了。我们回忆一下最开始讲的计量论文的流行形式：
- 一、引言
- 二、文献回顾
- 三、理论机制分析
- 四、计量模型与数据
 - ——面板数据模型+IV
- 五、计量结果
 - ——首先，做基准回归（核心变量+必备控制变量）；
 - ——然后，做备择回归（加入不同控制变量）；
 - ——第三，做固定效应回归
 - ——第四，做IV
 - ——第五，换Y、X重复上述步骤；
 - ——第六，换不同的样本重复上述步骤等等
- 六、结论与政策含义

- 
- 看了“黑客教程”之后，是不是觉得可以写出计量论文了。这个肯定没有问题。
 - 但是，大家不能满足于此，我们的目的不仅仅是写出来，还要发出来。
 - 也就是说，我们要想方设法去提高计量论文的质量。
 - ——idea: 好的、热门的
 - ◆ 我国的各种政策试点
 - ——方法: 最流行的方法
 - ◆ DID、RD、匹配法与合成控制法

第三讲 DID

- 上面提到了我国的各种政策试点：我们也可以将其看作是一种社会实验。在深圳实施改革开放，看看深圳这个小渔村能不能发展成大城市。如果不行，就算了吧。如果成功了，我们就可以把改革开放推广到全国。所以有了我们现在的幸福生活。
- 实验这东西，我们在物理、化学等领域里经常听说。经济学中经常举的一个例子就是：**新药临床试验**。
- **随机的**选择一些病人来服用这种新药，而另一些病人服用无害的无效替代品（安慰剂）。
- 从目前来看，随机控制实验也是经济学中最重要的关注点。现在很多学者都“绞尽脑汁”去寻找各种政策的“随机控制实验（自然实验）”。如果你找到了，恭喜你成功了一大半了！

理想实验

- 处理组：随机选择一部分病患服用试验药品；
- 控制组：随机选择一部分病患服用无害无效的安慰剂。
- 同理，实施改革开放的城市（深圳）就是处理组，没有实施改革开放的城市就是控制组。
- 那么，服用新药的病患可能会出现病情变化，而未服用新药的病患也可能出现病情变化。这两种病情变化的差异，我们就推断是新药起的作用。
- 在理想实验中，处理组与控制组的病患选择完全是随机的。因此，解释变量（是否服用试验药品）与扰动项不相关。这样，无论是否有遗漏变量，都不会出现遗漏变量偏误。

- 那么，我们如何估计新药的药效呢？
- 此时，我们需要特别注意的是，核心解释变量变成了二值（是or否）——虚拟变量。
- 那么，服用 $X_i=1$ ；未服用 $X_i=0$ 。 Y_i 表示病情
- 服用新药后的病情 $\bar{Y}_{i,treat} = E(Y_i|X_i = 1)$ ，未服用的病情

$$\bar{Y}_{i,control} = E(Y_i|X_i = 0)$$

- 新药的药效： $E(Y_i|X_i = 1) - E(Y_i|X_i = 0)$
- 回归方程：

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

0

1

平均处理效应ATE

- 我们现在关心的还是估计出 β_1 。

$$\tilde{\beta}_1^{OLS} = \bar{Y}_{i,treat} - \bar{Y}_{i,control}$$

- 这个估计量叫“差分估计量”。
- **特别注意：**虽然，在理想实验中，服用新药的病人是随机分配的，无论是否存在遗漏变量，服用新药（处理）对病情影响的估计量总是无偏、一致的。但是，在实践中，我们通常还是会加入如控制变量W，因为在回归中加入控制变量W可以提高 β_1 的OLS估计量的效率（Stock and Watson, 2015）。如果控制变量W对解释Y的变动有帮助，那么，回归中加入控制变量W可以降低 β_1 的OLS估计量的标准误。

- 20世纪80年代初期，美国田纳西州进行了一项围棋4年的初级教育阶段班级缩减的实验，**STAR**项目。这项实验主要是想评价小班教学的效果。这次小班教学实验划分了三种班级规模：普通规模——22-25名学生/班/教师，无助教；小班——13-17名学生/班/教师，无助教；普通规模，有助教。学生和老师在入学时都是*随机分配*到不同班级规模。这项实验的第一年，大约有6400名学生，108个小班，101个无助教普通班，99个有助教普通班。4年期间，共有11600名学生和80所学校参与小班教学实验。
- 两个处理组：小班（**SC**）、有助教普通班（**RA**）
- 一个控制组：无助教普通班

$$Y_i = \beta_0 + \beta_1 SC_i + \beta_2 RA_i + W_i \gamma_i + u_i$$

Table 2: 小班教学实验的效应：控制变量

解释变量	(1)	(2)	(3)	(4)
小班	13.90** (2.45)	14.00** (2.45)	15.93** (2.24)	15.89** (2.16)
有助教普通班	0.31 (2.27)	-0.60 (2.25)	1.22 (2.04)	1.79 (1.96)
教师执教年数		1.47** (0.17)	0.74** (0.17)	0.66** (0.17)
男孩				-12.09** (1.67)
免费午餐				-34.70** (1.99)
黑人				-25.43** (3.50)
其他种族				-8.50 (12.52)
常数项	918.04** (1.63)	904.72** (2.22)		
学校指标	no	no	yes	yes
$\overline{R}^2$	0.01	0.02	0.22	0.28
Obs.	5786	5766	5766	5748

注：(1)1-4列分别为全样本，以及1-3年级样本；

准实验或自然实验

- 社会的理想随机实验成本太大
- 但我们有想利用它的随机性
- 在实践中，我们通常见到的是一种非实验情形，但它又具有某些随机性——准实验或自然实验
- 两种类型的自然实验：
 - （1）个体是否受到“处理”，“*似乎*”是随机决定的。这种情形就可以利用前面的“差分估计量”来计算处理效应；
 - （2）随机变动“*似乎*”只是部分决定了是否被处理。这个时候，因果效应就可以利用IV回归。回忆一下第二讲中构造IV的方法就是分离出与误差项无关的成分，而这种自然实验中的随机变动部分就提供了工具变量。


双重差分(DID)

- 在自然实验中，个体接受处理与否似乎是随机分配的
- 但是我们并不能控制这种随机性，因此，我们不能估计 β
- 有一种方法可以消除上述问题——DID
- **核心思想：**不去比较 Y 之间的差异，而是比较 ΔY 之间的差异。

高铁的经济增长效应

- 如果高铁穿过城市 i ， $D_i=1$ ；没有经过， $D_i=0$ ；
- 那么，右图中，武汉、南京都是有高铁的 $D_i=1$ ；合肥没有高铁 $D_i=0$ 。
- **问题：**修了高铁后，武汉和南京是不是增长得更快了？
- 估计办法：我们算出两类城市GDP的平均之差

$$E(Y_i|D_i = 1) - E(Y_i|D_i = 0)$$



- 那么，这样做是不是就得到了我们感兴趣的铁路效应呢？
- 我们想想，万一被铁路穿过的城市在建铁路之前**GDP**增长就高呢？
- 为了解决这个问题，我们需要观察到至少两期，第一期是建铁路之前（**Gw₀**、**Gh₀**），第二期是建铁路之后（**Gw₁**、**Gh₂**）；
- 第一次差分，我们将武汉前后两期的经济增长相减**Gw₁-Gw₀**

$$\Delta Y_i = \frac{1}{N} \sum (Y_{i,after} - Y_{i,before})$$

它计算的实际上是城市*i*建铁路前后平均**GDP**的增长

- 第二次差分：

$$ATE = E(\Delta Y_i | D_i = 1) - E(\Delta Y_i | D_i = 0)$$

- 这一步就把两类城市在修建铁路之前和之后的**GDP**增长的差异给算出来了，这就是我们要的处理效应，即修建铁路之后对城市经济的促进作用。

- 另一种表示方法：
- 记 $T=1$ ，如果时间为建铁路之后； $T=0$ ，如果时间为建铁路之前

Table 3: DID估计量

Treated	D=1	D=0
T=1	1	0
T=0	0	0

- **Treated**表示在某一时期，某城市是否修建了铁路。从表3可以看出，在 $T=0$ 时期，没有城市修建铁路，而在 $T=1$ 期，也只有 $D=1$ 的城市修建了铁路。

- 因此, $Treated = D_i \times T$
- 回归方程:

$$Y_{it} = \alpha D_i + \beta T + \gamma D_i \times T + u_{it}$$

- 首先, 我们将上式在时间维度上做一次差分:


$$\Delta Y_i = \beta + \gamma D_i + \Delta u_i$$

- 然后, 我们在城市维度上做一次差分:

$$E(\Delta Y_1 - \Delta Y_0) = \gamma$$

- 到此, 我们得到了建铁路的经济增长效应DID估计量

共同趋势假设



- 两个组别在不处理的情况下，Y的趋势是一样的。
- 实践中，common trend的假设可能是不对的，那怎么办？如果这个问题存在，我们可以进一步假设在控制了某些外生变量之后，common trend 是对的。

$$Y_{it} = \alpha D_i + \beta T + \gamma D_i \times T + X' \delta + u_{it}$$

- 也就是说，不管怎么样，要用**DID**，处理组和控制组必须有共同趋势。
- 那么，我们如何检验和处理非共同趋势问题呢？

- 方法一、画时间趋势图
- 如果在政策干预前有多期数据，则可分别画处理组与控制组的时间趋势图（类似于上图），并直观判断这两组的时间趋势是否平行（比如，考察是否存在Ashenfelter's dip）。如果二者大致平行，则可增强对平行趋势假定的信心。然而，即使在政策干预前两组的时间趋势相同，也无法保证二者在干预后的时间趋势也相同（后者本质上不可观测，因为时间效应已与处理效应混合在一起）。另外，如果只有两期数据，则无法使用此法。
- 方法二、加入更多的控制变量
- 从上文的讨论可知，非平行趋势可能由于遗漏变量所导致，故在回归方程中加入更多控制变量，或可缓解内生性。但此法在实践中不易实施。

- 方法三、假设线性时间趋势
- 如果假设时间趋势为线性函数，则可加入每位个体的时间趋势项：在具体回归时，加入个体虚拟变量与时间趋势项 $t = 1, 2, \dots, T$ 的交互项即可。然而，线性时间趋势毕竟是比较强的假定，不一定能成立。故此法也不完全解决问题，但可作为稳健性检验。
- 方法四、三重差分法
- 在一定条件下，可通过引入两个控制组，进行三次差分，称为“三重差分法”（difference-in-differences-in-differences，简记DDD），这样可以更好地控制时间趋势的差异，使得平行趋势假定更易成立。有关DDD的进一步介绍，参见陈强（2014，第343页）。

DID的stata操作

- 安装DID的命令:
- `ssc install diff, replace`

```
. ssc install diff,replace
checking diff consistency and verifying not already installed...

the following files will be replaced:
  c:\ado\plus\d\diff.ado
  c:\ado\plus\d\diff.sthlp

installing into c:\ado\plus\...
installation complete.
```

- 命令结构:
- Diff outcomevar [if] [in] [weight], period(varname)
treated(varname) [cov(varlist kernel id(varname) bw(\#)
ktype(kernel) rcs qdid(quantile) pscore(varname) logit
support addcov(varlist cluster(varname) robust bs
reps(int) test report nostar export(filename)]

- 不控制任何协变量:
- diff fte, period(t) treated(treated) robust

```
. diff fte,period(t) treated(treated) robust
```

DIFFERENCE-IN-DIFFERENCES ESTIMATION RESULTS

Number of observations in the DIFF-IN-DIFF: 780

	Baseline	Follow-up	
Control:	76	76	152
Treated:	314	314	628
	390	390	

Outcome var.	fte	S. Err.	t	P> t
Baseline				
Control	20.013			
Treated	17.069			
Diff (T-C)	-2.944	1.440	-2.04	0.041**
Follow-up				
Control	17.523			
Treated	17.518			
Diff (T-C)	-0.005	1.037	-0.00	0.996
Diff-in-Diff	2.939	1.774	1.66	0.098*

R-square: 0.01

* Means and Standard Errors are estimated by linear regression

**Robust Std. Errors

Inference: * p<0.01; ** p<0.05; * p<0.1

- 控制协变量:
- diff fte, period(t) treated(treated) robust cov(bk kfc roys)

```
. diff fte,period(t) treated(treated) robust cov( bk kfc roys)
```

DIFFERENCE-IN-DIFFERENCES WITH COVARIATES

DIFFERENCE-IN-DIFFERENCES ESTIMATION RESULTS

Number of observations in the DIFF-IN-DIFF: 780

	Baseline	Follow-up	
Control:	76	76	152
Treated:	314	314	628
	390	390	

Outcome var.	fte	S. Err.	t	P> t
Baseline				
Control	21.342			
Treated	19.003			
Diff (T-C)	-2.339	1.282	-1.83	0.068*
Follow-up				
Control	18.852			
Treated	19.452			
Diff (T-C)	0.600	0.912	0.66	0.511
Diff-in-Diff	2.939	1.573	1.87	0.062*

R-square: 0.19

* Means and Standard Errors are estimated by linear regression

**Robust Std. Errors

Inference: * p<0.01; ** p<0.05; * p<0.1

- 检验协变量的平衡性
- diff fte, period(t) treated(treated) robust cov(bk kfc roys) test

```
. diff fte, period(t) treated(treated) robust cov(bk kfc roys) test
```

TWO-SAMPLE T TEST

```
Number of observations (baseline): 390
```

	Before	After
Control:	76	- 76
Treated:	314	- 314
	390	-

```
t-test at period = 0:
```

Variable(s)	Mean Control	Mean Treated	Diff.	t	Pr(T > t)
fte	20.013	17.069	-2.944	2.43	0.0155**
bk	0.447	0.411	-0.037	0.58	0.5634
kfc	0.158	0.217	0.059	1.14	0.2569
roys	0.224	0.248	0.025	0.45	0.6533

```
*** p<0.01; ** p<0.05; * p<0.1
```

- DID+分位数
- diff fte, period(t) treated(treated) cov(bk kfc roys) qdid(0.9)

```
. diff fte, period(t) treated(treated) cov(bk kfc roys) qdid(0.9)
QUANTILE DIFFERENCE-IN-DIFFERENCES WITH COVARIATES
```

DIFFERENCE-IN-DIFFERENCES ESTIMATION RESULTS

Number of observations in the DIFF-IN-DIFF: 780

	Before	After		
Control:	76	76	152	
Treated:	314	314	628	
	390	390		
Outcome var.	fte	S. Err.	t	P> t
Before				
Control	35.000			
Treated	28.250			
Diff (T-C)	-6.750	2.659	-2.54	0.011**
After				
Control	29.500			
Treated	29.000			
Diff (T-C)	-0.500	2.524	0.20	0.843
Diff-in-Diff	6.250	3.668	1.70	0.089*

R-square: 0.11

* Values are estimated at the .9 quantile

Inference: * p<0.01; ** p<0.05; * p<0.1

第四讲 断点回归设计

- 断点回归（**RD**）在国内超级火，“满天尽是**RD**”。
- 还有人说：论文发表不轻松，要把断点为我用！
- 你要你能找到一个“断点”，再次恭喜你，又成功发表在望。
- **RD**确实是个好方法。它等于是在断点附近的局部随机试验。这一点赖以成立的前提条件，并不难以满足。此外，跟随机试验中全域（**global**）随机性可以被检验一样，**RDD**等于局部随机试验的假设，也可以通过观察前定变量的分布是否平衡来检验。从这个意义上讲，**RD**方法比**IV**、**DiD**更接近于随机试验。随机试验是因果识别的终极杀招，越接近随机试验的方法当然越好！

断点回归估计量

- 在自然实验中，还可能出现一种情形：个体接受处理完全或部分依赖于某个可观测变量 W 是否超过某一阈值（门槛）。
- 例如，学生的绩点 $GPA(W) < 2.5$ ，他就要重修；而 $GPA(W) \geq 2.5$ 的学生就不用重修。那么，重修对成绩的效应是什么？
- 重修=处理组；不重修=控制组。
- 那么，学生进入处理组还是控制组就取决于他的绩点 $GPA(W)$ 是否低于2.5这个门槛。
- 绩点变量 W 称为参考变量。

- 我们来看看断点回归的经典文献Lee（2008，JoE）、Lee and Lemieux（2010，JEL）：


Journal of Economic Literature 48 (June 2010): 281–355
<http://www.aeaweb.org/articles.php?doi=10.1257/jel.48.2.281>

Regression Discontinuity Designs in Economics

DAVID S. LEE AND THOMAS LEMIEUX[✉]

- Lee(2008,JoE)对美国各地区众议员选举中在位党在竞选中是否具有优势的分析。美国两大党派在选举中获得的选票份额超过对手时，该党就是在位党。Lee以民主党选票份额与共和党选票份额之差作为参考变量 W ，间断点为0，只要上次选举中参考变量大于0，即意味着民主党在位，否则共和党在位。

Regression function fit



- 上图显示了，下一次的选举得票份额是现在两党得票之差 W 的函数。如果阈值 w_0 的唯一作用只是识别在位党派，那么，下一次选举得票份额在阈值处的“跳跃”就是竞选中的在位优势的效应估计值。
- 更一般化的分组规则：


$$D_i = \begin{cases} 1 & \text{if } x_i \geq w_0 \\ 0 & \text{if } x_i \leq w_0 \end{cases}$$

- 假设在选举前，各党派的得票份额的结果 y_i 与 x_i 之间存在如下线性关系：

$$y_i = \alpha + \beta x_i + \epsilon_i$$

我们从图5可以看出，在 $x_i = w_0$ 处， y_i 与 x_i 的线性关系存在一个向上跳跃（jump）的断点。但是，得票率(%)为49.8、49.9、50、50.1、50.2等，可以认为党派在各个方面没有系统差异，因此，这个跳跃发生的唯一原因只可能是 D_i 的处理效应，也就是在位党的优势。

Regression function fit



- 由上图可以明显地看出，选举结果与在位之间的关系是一个分段函数。
- 引入虚拟变量，表示不同段函数具有不同的截距。

$$y_i = \alpha + \beta(x_i - w_0) + \delta D_i + \gamma(x_i - w_0)D_i + \epsilon_i$$

引入交互项 $(x_i - w_0)D_i$ 是为了允许在断点两侧的回归线斜率不同。对方程（12）进行OLS回归，得到的 $\tilde{\delta}$ 就是**断点回归估计量**，也称为局部平均处理效应（LATE）。

- 估计断点估计量时，**要特别注意：**

1、方程（12）中包含了交互项。如果断点两侧的回归线斜率相同，则可不包含交互项。但在实践中，一般断点两侧斜率会不同，因此，如果不包含交互项，则可能导致断点右（左）侧的观测值影响对左（右）侧截距的估计，从而引起偏误；

2、在有交互项的情形下，如果方程中没有 $(x_i - w_0)$ ，而是使用的 x_i ，那么，虽然 $\tilde{\delta}$ 还是断点两侧的距离之差，但是并不等于这两条回归线在 $(x_i = w_0)$ 处跳跃的距离。

- 断点回归根据断点处，个体接受处理的概率，划分为：
- 精确断点回归（**SRD**）
- 模糊断点回归（**FRD**）

又分为精准断点回归（sharp RD）和模糊断点回归（fuzzy RD）。SRD在断点 $x_i = w_0$ 处，个体接受处理的概率从0跳跃到1，而FRD在断点 $x_i = w_0$ 处，我们只知道个体接受处理的概率从a跳跃到b，而 $0 \leq a \leq b \leq 1$ 。

精确断点回归

在Sharp RDD中，接受处理完全由参考变量 W 是否超过某一阈值决定：

当 $W \geq 0$ 时，民主党是在位党，当 $W < 0$ 时，共和党是在位党；即用 D 表示

民主党是否在位，当 $W \geq 0$ 时， $D_i = 1$ ，当 $W < 0$ 时， $D_i = 0$ 。在这种情形

- 由此，我们可以看到，上述Lee(2008)的例子是一个精准断点回归。
- 那么，我们是否还可以利用（12）式进行OLS估计呢？
- 可以是可以，但是这存在两个问题：

- 1、可能存在遗漏变量偏误，例如如果回归中还有高次项 $(x_i - w_0)^2$
- 2、断点回归可以看作是“局部随机实验”，因此从原理上看，我们应该只是用断点附近的观测值样本，但我们在实践中却是用全部样本进行回归。

- 为了解决上述问题，我们可以引入高次项，并限定 x 的范围 $w_0 - h \leq x_i \leq w_0 + h$
- 那么，分段回归方程可以变为

$$y_i = \alpha + \beta_1(x_i - w_0) + \beta_2(x_i - w_0)^2 + \delta D_i + \gamma_1(x_i - w_0)D_i + \gamma_2(x_i - w_0)^2 D_i + \epsilon_i$$

- 问题真的解决了吗？从理论上讲是的。但是实践中的问题没有解决。
- 我们并不知道 h 是多少？因此，还是估计不出来 δ 。

- 在确定 h 时，一般是采用非参数回归来最小化均方误差（**MSE**）。直观来说， h 越小，偏差越小，但是估计方差会变大；反之亦然。
- 一般，我们采用三角核与矩形核方法估计最优带宽 h 。
- 这个时候，我们就可以用**stata**的**RD**命令来估计出断点回归估计量 δ 。

协变量问题

- 1、我们可以在RD回归式中加入影响Y的协变量。虽然断点回归是局部随机实验，包不包括协变量并不影响断点回归估计量的一致性，但是加入协变量的好处为：加入协变量可以解释被解释变量Y，那么，就可以减低方差。使得估计更准确。但坏处是：如果加入的协变量是内生变量，与误差项相关，那么就会影响估计量。
- 2、实际上，断点回归有个隐含假设：协变量在断点处不存在跳跃，是连续的。如果协变量在断点处也存在跳跃，那么，我们就不能把 δ 全部归于处理效应。因此，在实践中，我们要现将所有的协变量作为被解释变量，进行断点回归，考察其分布是否在断点处存在跳跃。

- 
- 此外，我们还应该注意“内生分组”问题。如果个体事先知道分组规则，并可通过自身行为来完全控制分组变量，那么，就可以自行选择进入处理组还是控制组，这就导致了随机分组失败，从而断点回归失灵。

小贴士

- 在实践中，我们建议同时汇报出以下情形，以确保结果稳健：
- 1、分别汇报三角核与矩形核的回归结果；
- 2、分别汇报使用不同带宽的结果；
- 3、分别汇报包含协变量与不包含协变量的结果；
- 4、进行模型设定检验时，包括检验分组变量与协变量的条件密度在断点处是否存在跳跃。

模糊断点

- 在Fuzzy RDD中，参考变量超过阈值会影响到是否接受处理，但这不是决定处理的唯一影响因素。例如，假设有些GPA在阈值以下的学生并没有参加短学期，而有些GPA超过阈值的学生又参加了短学期。如果临界值规则是一个决定treated非常复杂的过程的一部分，那么上述情况就可能会出现。

断点回归stata操作

- 下面，我们使用Lee(2008)的数据来演示一下断点回归的stata操作。这个数据集中包括两个变量：**vote**表示民主党的选票份额；**margin**表示民主党在上次竞选中获得的选票与共和党选票份额之差。因此，**margin**就是参考变量，如果**margin**大于0，民主党就是在位党，这是一个SRD。我们感兴趣的问题是，在位党是否会获得优势。样本共有4900个。

- **第一步，下载安装断点回归命令。**
- Calonico et al. (2014) 提供了一个专门进行断点回归分析的程序包 `rdrobust`，里面包含三个命令：`rdplot`——断点回归图形；`rdbwselect`——选择最优带宽；`rdrobust`——估计断点回归估计量。
- **findit** `rdrobust`（找到该命令）



Search of official help files, FAQs, Examples, SJs, and STBs

```
SJ-14-4  st0366  . . . Robust data-driven inference in reg.-discontinuity design
          . . . . . S. Calonico, M. D. Cattaneo, and R. Titiunik
          (help rdrobust, rdbwselect, rdplot if installed)
Q4/14    SJ 14(4):909--946
conducts robust data-driven statistical inference in
regression-discontinuity designs
```

Web resources from Stata and other users

(contacting <http://www.stata.com>)

2 packages found (Stata Journal and STB listed first)

st0366 1 from <http://www.stata-journal.com/software/sj17-2>

SJ17-2 st0366_1. Update: Local polynomial... / Update: Local polynomial regression-discontinuity / estimation with robust bias-corrected confidence / intervals and inference procedures / by Sebastian Calonico, University of Miami, / Miami, FL / Matias D. Cattaneo, University of

st0366 from <http://www.stata-journal.com/software/sj14-4>


SJ14-4 st0366. Robust data-driven inference... / Robust data-driven inference in the regression- / discontinuity design / by Sebastian Calonico, University of Miami, / Coral Gables, FL / Matias D. Cattaneo, University of Michigan, / Ann Arbor, MI / Rocio Titiunik, University of

[\(click here to return to the previous screen\)](#)

(end of search)

- 点击 “st0366_1 from <http://www.stata-journal.com/software/sj17-2>”，进入页面再点击 “click here to install”进行安装。
- *第二步，画图。* 输入
- `rdplot vote margin, c(0) nbins(50)`

Regression function fit



- 第三步，选择最优带宽。输入
- `rdbwselect vote margin, c(0) kernel(uni) all`

```
. rdbwselect vote margin, c(0) kernel(uni) all
Computing CCT bandwidth selector.
Computing IK bandwidth selector.
Computing CV bandwidth selector.
```

Bandwidth estimators for RD local polynomial regression

Cutoff c = 0	Left of c	Right of c
Number of obs	2740	3818
Order loc. poly. (p)	1	1
Order bias (q)	2	2
Range of margin	1.000	1.000

```
Number of obs =      6558
NN matches    =         3
Kernel type   =   Uniform
Min BW grid   =   0.00300
Max BW grid   =   0.99970
Length BW grid =   0.04984
```

Method	h	b	rho
CCT	.1198642	.2299834	.5211865
IK	.1781139	.2221868	.8016402
CV	.30201	NA	NA

- 
- *第四步，估计断点回归估计量。* 输入：
 - rdrobust vote margin, c(0) kernel(uni) all

```
. rdrobust vote margin, c(0) kernel(uni) all
Preparing data.
Computing bandwidth selectors.
Computing variance-covariance matrix.
Computing RD estimates.
Estimation completed.
```

Sharp RD estimates using local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	6558
			NN matches =	3
Number of obs	698	729	BW type =	CCT
Order loc. poly. (p)	1	1	Kernel type =	Uniform
Order bias (q)	2	2		
BW loc. poly. (h)	0.120	0.120		
BW bias (b)	0.230	0.230		
rho (h/b)	0.521	0.521		

Outcome: vote. Running variable: margin.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
Conventional	.06622	.01126	5.8822	0.000	.044155	.088285
Robust	-	-	4.8784	0.000	.037599	.088101

All estimates.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
Conventional	.06622	.01126	5.8822	0.000	.044155	.088285
Bias-corrected	.06285	.01126	5.5828	0.000	.040785	.084915
Robust	.06285	.01288	4.8784	0.000	.037599	.088101

- 下面，我们来详细介绍一下上述三个rd命令的基本语法格式：
- `rdplot~~~depvar~~~indepvar~~~[if]~~~[in][,c(\#)~~~p(\#)~~~kernel(\#)~~~weights()~~~h(\#~~~\#)~~~nbins(\#~~~\#)~~~binsel
ect()~~~scale(\#~~~\#)~~~ci()~~~shade~~~generate(id_var~~~
meanx_var~~~meany_var~~~cil_var~~~cir_var)~~~graph_op
tions(gphopts)~~~hide]`

- `rdbwselect~~~depvar~~~indepvar~~[if]~~[in][,c(\#)~~p(\#)~~q(\#)~~deriv(\#)~~fuzzy(fuzzyvar[sharpbw])~~covs(\#)~~kernel(\#)~~bwselect()~~scaleregul(\#)~~vce(vcetype[vceopt1~~vceopt2])~~all]`
- `rdrobust~~~depvar~~~runvar~~[if]~~[in][,c(\#)~~p(\#)~~q(\#)~~deriv(\#)~~fuzzy(fuzzyvar[sharpbw])
covs(\#)~~kernel(\#)~~h(\#~~\#)~~b(\#~~\#)~~rho(\#)~~b
wselect()~~scaleregul(\#)~~scalepar(\#)~~vce(vcetype[v
ceopt1~~vceopt2])~~level(\#)~~all]`

第五讲 匹配法

我们回忆一下在理想实验中，平均处理效应（ATE）等于服用新药之后的病情（ $E(Y_{1i}|D_i = 1)$ ）与没有服用新药病情（ $E(Y_{0i}|D_i = 0)$ ）之间的差异。

即 $ATE = E(Y_{1i}|D_i = 1) - E(Y_{0i}|D_i = 0)$ 。

- 数学变换

$$\begin{aligned} ATE &= E(Y_{1i}|D_i = 1) - E(Y_{0i}|D_i = 0) \\ &= [E(Y_{1i}|D_i = 1) - E(Y_{0i}|D_i = 1)] + [E(Y_{0i}|D_i = 1) - E(Y_{0i}|D_i = 0)] \end{aligned}$$

- 上式显示，我们可以把**ATE**分解成两个部分（由中括号表示）：
 - 第一个部分是“参与者平均处理效应（ATT）”——项目实际参与者的平均处理效应；
 - 第二部分是选择偏差——假设参与者和未参与者的处理效应之差（实际上两类人都未参与项目）。
-
- 从政策制定者的角度来看，他们可能更关心**ATT**，因为这是政策或项目实施后的毛收益，我们只需要将这个毛收益与政策成本进行比较，就能判定这个政策是否值得。

- ATE 与ATT 之间是存在一个选择偏差。
- **需要注意的是**，这里的选择偏差与第五讲中的样本选择偏误有所不同。样本选择偏误是所选取的样本不是总体中的代表性样本所引起的偏误，这时通常不考虑政策或项目效应。
- 有两种方法解决：
 - I. 匹配估计量
 - II. DID-PSM估计量

I. 匹配估计量

- 使用条件：假设个体根据可观测变量来选择是否参与项目
- 下面，我们用一个就业培训项目为例。在对这个项目进行效应评估时，我们除了能观测到人们是否参与了该项目 D_i 和项目实施前后的收入 Y_i ，我们还能观测到参与者的一些个体特征，例如年龄、受教育程度、肤色、婚否、性别等——协变量。
- 如果个体是否参与项目完全由某些协变量 X 决定的，那么，我们就可以利用匹配估计方法来估计出处理效应。

- 思想：实践中，个体 i 参与培训了（处理组），他就不可能又“穿越”回到过去不参加培训。这个时候，我们就需要在没有参加培训的那些人（控制组）找到某个或某些人 j ，
- 那么怎么找呢？
- 上面说过，参与项目 D_i 完全取决于可观测变量 X_i ，那么，自然就是找那些与参与者 i 有相近 X 的未参与者 j 。我们选择的 X_j 与 X_i 越接近， j 参与培训的概率就越接近 i 。那么，我们就可以把 j 的收入 Y_j 近似当作 i 在没有参与培训情形下的收入，然后把 i 的实际收入 Y_i 减去这个近似收入 Y_j ，即可得到培训的处理效应，即**匹配估计量**。

Table 4: 匹配估计

i	D_i	X_i	Y_i	匹配对象	$\tilde{Y}_{0i}$	$\tilde{Y}_{1i}$
1	0	2	7	5	7	8
2	0	4	8	4,6	8	7.5
3	0	5	6	4,6	6	7.5
4	1	3	9	1,2	7.5	9
5	1	2	8	1	7	8
6	1	3	6	1,2	7.5	6
7	1	1	5	1	7	5

- 根据匹配估计的思想，是否参加项目 D 只依赖于 X ，而且我们要从未参加组（ $D=0$ ）里为参加者（ $D=1$ ）找到 X 相近的那些人，例如，我们要从1-3中为4-7找到 X 相近的人，第7个人的 $X=1$ ，而1-3中 X 最接近1的是第一个人的 $X=2$ ，因此，与第7个人匹配的对象就是第1个人。那么，我们就应该把第1个人的 $Y=7$ 当做第7个人没有参加项时的 $Y=7$ ，而实际参与项目的 $Y=5$ ，因此，该项目的效应就是 $5-7=-2$ 。其他人也这样匹配。


- 两个技术细节需要特别注意：
- 第一，在寻找匹配对象时是否允许匹配对象放回。放回就是说，当表3中的第4个人与第2个人匹配了，但是在对第6个人进行匹配时，第2个人仍然在备选之列，也就是第2个人匹配之后又放回备选对象行列，可以进行下一次匹配。而不放回，就意味着2与4匹配之后，2就不能进行下次匹配，那么6只能与1进行匹配。
- 第二，是否允许匹配对象并列。也就是说，4与1、2的X都比较接近，那么，在允许并列的情形下，我们会将1、2的Y的均值作为4的Y_4。如果不允许并列，软件就会根据数据排列的顺序来选择匹配对象及其Y_4，例如，在不允许并列时，根据表3数据的排列顺序，与4匹配的就是1，那么Y_1就会作为4的Y_4。

- 一般来说，匹配估计量会存在偏差，因为 X_i 不可能与 X_j 完全相同。
- 那么，在非精确匹配的情形下：（1）一对一匹配，偏差较大，方差较小；（2）一对多匹配，偏差较小，方差加大。
- 经验法则：最好进行一对四匹配，这样能使均方误差(MSE)最小。

PSM

- 上面就是匹配估计法的最基本思想：就是找到两组中X最接近的对象进行匹配。虽然原理很简单，但是实际操作起来可就难了。因为在实践中，我们通常不会像表3那样，D依赖的X只有单一变量，而是X中会包含很多个变量。也就是说，我们要根据多个协变量同时进行比较，例如对不同人的年龄、受教育程度、性别等同时进行比较，这个时候就可能会遇到，两个人年龄相仿，但受教育程度差距很大，受教育程度相同，但年龄差距有很大，这个时候我们要这么比较这匹配对象是否接近呢？
- 有效的武器——PSM

- 那么，PSM的思想是什么呢？说简单也简单，说难也难！
- 简单是因为，我们就是要评判不同对象之间是否相似，但在多个X情况下，我们无从下手。那么，我们想法办把多个X转换成一个指标，即通过某种函数 $f(X)$ ，把多维变量变成一维变量，这个一维变量就是倾向得分（PS）。然后，我们就可以根据这个倾向得分来进行上述匹配（PSM）。



- 难是因为，这个转换函数 $f(X)$ 到底是什么？这个问题我们就不展开了。

PSM计算处理效应的步骤

- （1）选择协变量X。
- （2）计算倾向得分，一般用logit回归；
- （3）进行倾向得分匹配。
 - ——经验法则：一般来说，标准化偏差不能超过10%，如果超过10%，我们就要重新返回第（2）步重新计算，甚至第（1）步重新选择匹配协变量，或者改变匹配方法。
- （4）根据匹配后的样本计算处理效应。

- 第三步中，得分匹配效果不好，可能要改变匹配方法：一、 k 邻近匹配；二、卡尺匹配或半径匹配；三、卡尺内最近邻匹配；四、核匹配；五、局部线性回归匹配；六、样条匹配。
- 在实践中，并没有明确准则来限定使用哪种匹配方法。
- **最常用的方法：**尝试不同的匹配方法，然后比较它们的结果，结果相似说明很稳健。结果差异较大，就要去深挖其中的原因。

PSM的局限

- （1）大样本；
- （2）要求处理组和控制组有较大的共同取值范围；
- （3）只控制了可观测的变量，如果存在不可观测的协变量，则会引起“隐性偏差”。

II. DID-PSM估计量

- 使用条件：假设个体根据不可观测变量来选择是否参与项目
- 如果存在根据不可观测变量进行选择时，会引起“隐性偏差”。
- 消除这种隐形偏差的方法：
- DID-PSM
- IV
- RD

匹配法stata操作

- 下面，我们用Dehejia and Wahba（1999）职业培训的数据来演示stata的匹配操作。
- 参加培训项目的个人就是处理组（treatment） $D_i=1$ ，没有参加 $D_i=0$

Treatment	Number of obs	Percent frequency
0	2,490	93%
1	185	7%

- 因变量是实际收入（RE78），自变量是年龄（age）、教育（educ）、是否结婚（marr）等

- 安装PSM命令: `ssc install psmatch2, replace`

```
. ssc install psmatch2,replace
checking psmatch2 consistency and verifying not already installed...

the following files will be replaced:
  c:\ado\plus\p\ptest.ado

installing into c:\ado\plus\...
installation complete.
```

- 通用命令格式: `psmatch2 treatvarname X1 X2 X3, outcome (y) logit ties ate common odds pscore (varname) quietly`
- `Treatvarname`: 实验变量或处理变量
- `X1 X2 X3`: 匹配变量或协变量
- `outcome (y)` 指定y为因变量
- `Logit`为得分估计模型, 默认为probit模型
- `Ate`表示同时汇报ATE ATU ATT
- `Common`表示仅对共同取值范围内个体进行匹配
- `pscore (varname)` 表示倾向得分变量

- PSM有多种匹配方法（算法）：
- 1、近邻匹配： `psmatch2 treatvarname X1 X2 X3, outcome (y) neighbor (k) logit ties ate common pscore (varname)`
- 选项“neighbor (k)”表示进行k近邻匹配，k=1时表示一对一匹配，k>1时表示一对多匹配
- 2、半径匹配： `psmatch2 treatvarname X1 X2 X3, outcome (y) radius logit ties ate common pscore (varname)`
- 选项“radius”表示半径匹配，也可加入卡尺选项“caliper ()”，括号中为实数，表示匹配精度
- 3、核匹配： `psmatch2 treatvarname X1 X2 X3, outcome (y) kernel_logit ties ate common pscore (varname)`

- 下面进行倾向得分匹配。首先，将数据随机排序
- `set seed 10101`
- `gen ranorder = runiform ( )`
- `sort ranorder`
- 下面进行一对一近邻匹配：
- `psmatcah2 TREAT AGE EDUC MARR, out(RE78) n(1)
ate ties logit common`

```
. psmatch2 treat age education black , out( re78 ) n(1) ate ties logit common
```

```
Logistic regression               Number of obs   =       445
                                LR chi2(3)        =       3.51
                                Prob > chi2        =       0.3192
Log likelihood = -300.34408       Pseudo R2      =       0.0058
```

treat	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
age	.0143112	.0136229	1.05	0.293	-.0123892	.0410116
education	.0793213	.0546484	1.45	0.147	-.0277876	.1864302
black	.0790505	.2625391	0.30	0.763	-.4355167	.5936176
_cons	-1.580782	.6798444	-2.33	0.020	-2.913252	-.2483115

There are observations with identical propensity score values.

The sort order of the data could affect your results.

Make sure that the sort order is random before calling psmatch2.

Variable	Sample	Treated	Controls	Difference	S.E.	T-stat
re78	Unmatched	6349.1435	4554.80112	1794.34238	632.853392	2.84
	ATT	6265.22469	4184.43609	2080.7886	752.124823	2.77
	ATU	4555.40953	6052.53629	1497.12676	.	.
	ATE			1738.55052	.	.

Note: S.E. does not take into account that the propensity score is estimated.

psmatch2: Treatment assignment	psmatch2: Common support		Total
	Off suppo	On suppor	
Untreated	2	258	260
Treated	3	182	185

- 标准差假设为同方差，但是这一假设可能不成立。因此，可以使用自助法（**bootstrap**）得到标准误。操作为
- `set seed 10101`
- `bootstrap r(att) r(atu) r(ate), reps(500):psmatch2 TREAT AGE EDUC MARR, out( RE78) n(1) ate ties logit common`
- 下面用`pstest`命令来检验此匹配是否较好地平衡了数据。
- `quietly psmatch2 TREAT AGE EDUC MARR, out( RE78) n(1) ate ties logit common`
- `pstest AGE EDUC MARR, both graph`

- 下面进行一对多匹配。
- `psmatch2 TREAT AGE EDUC MARR, out(RE78) n(4)
ate ties logit common quietly`
- 下面进行一对多匹配均发生在卡尺0.01内。
- `psmatch2 TREAT AGE EDUC MARR, out(RE78) n(4)
cal(0.01) ate ties logit common quietly`
- 半径匹配
- `psmatch2 TREAT AGE EDUC MARR, out(RE78) radius
cal(0.01) ate ties logit common quietly`

- 核匹配
- `psmatch2 TREAT AGE EDUC MARR, out(RE78) kernel
ate ties logit common quietly`
- PSM+DID
- `diff fte , treated(treated) period(t) id(id) kernel cov(bk
kfc roys) logit report support test`

```
. diff fte , treated( treated ) period(t) id( id ) kernel cov( bk kfc roys ) logit report support test
Report - Propensity score estimation with logit command
Attention: _pscore is estimated at baseline
```

```
Iteration 0: log likelihood = -192.3521
Iteration 1: log likelihood = -191.16732
Iteration 2: log likelihood = -191.15777
Iteration 3: log likelihood = -191.15777
```

Logistic regression	Number of obs	=	390
	LR chi2(3)	=	2.39
	Prob > chi2	=	0.4957
Log likelihood = -191.15777	Pseudo R2	=	0.0062

treated	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
bk	.2348396	.3738018	0.63	0.530	-.4977985	.9674777
kfc	.6359888	.4478876	1.42	0.156	-.2418548	1.513832
roys	.4248832	.4173825	1.02	0.309	-.3931715	1.242938
_cons	1.098612	.3202563	3.43	0.001	.4709215	1.726303

Matching iterations...

TWO-SAMPLE T TEST

Test on common support

Number of observations (baseline): 390

	Before	After
Control:	76	- 76
Treated:	314	- 314
	390	-

t-test at period = 0:

Weighted Variable(s)	Mean Control	Mean Treated	Diff.	t	Pr(T > t)
fte	20.006	17.069	-2.937	2.79	0.0056***
bk	0.465	0.411	-0.054	1.08	0.2797
kfc	0.146	0.217	0.071	1.81	0.0704*
roys	0.285	0.248	-0.036	0.81	0.4174

*** p<0.01; ** p<0.05; * p<0.1

Attention: option kernel weighs variables in cov(varlist)

Means and t-test are estimated by linear regression

第六讲 合成控制法

- 随机性是个好东西！
- 但是我们很难随机的分配“处理组”和“控制组”
- 而且，现实中，往往接受处理的个体，不可能又不接受处理。也就是说，在处理组中的个体不可能同时在控制组中。
- 所以我们想尽办法去“构造”相似的控制组个体。

- 
- 选择控制组是一门艺术。确实，寻找适当的控制组（**control group**），即在各方面都与受干预地区相似却未受干预的其他地区，以作为处理组（**treated group**，即受到干预的地区）的反事实替身（**counterfactuals**）。但通常不易找到最理想的控制地区（**control region**），在各方面都接近于处理地区（**treated region**）。

- 比如，要考察仅在北京实施的某政策效果，自然会想到以上海作为控制地区；但上海毕竟与北京不完全相同。或可用其他一线城市（上海、广州、深圳）构成北京的控制组，比较上海、广州、深圳与北京在政策实施前后的差别，此方法也称“比较案例研究”（**comparative case studies**）。但如何选择控制组通常存在主观随意性（**ambiguity**），而上海、广州、深圳与北京的相似度也不尽相同。
- 前面，我们简单介绍了匹配方法——通过能体现个体特征的协变量的相似度来构造出一个“控制地区”的结果。
- 除了上述**PSM**方法之外，还有另一种构造“控制组”的方法——合成控制法（**Synthetic Control Method**）。

- 合成控制法是由Abadie and Gardeazabal (2003)提出来研究西班牙巴斯克地区（Basque country）恐怖活动的经济成本。
- **核心思想：**虽然无法找到巴斯克地区的最佳控制地区，但通常可对西班牙的若干大城市进行适当的线性组合，以构造一个更为贴切的“合成控制地区”（synthetic control region），并将“真实的巴斯克地区”与“合成的巴斯克地区”进行对比，故名“合成控制法”。*合成控制法的一大优势是，可以根据数据（data-driven）来选择线性组合的最优权重，避免了研究者主观选择控制组的随意性。*

- **Abadie et al.(2010)**用合成控制法研究了美国加州香烟控制99法案对加州香烟消费的影响。为了限制香烟消费，1988年11月，加州政府通过了99法案，主要内容是将香烟消费税每包提高25美分，该法案1989年1月正式生效，作者主要考察这一政策对香烟消费的抑制作用到底有多大。由此，我们知道，香烟消费税在加州地区改变（提高了），而在美国其他州并没有变化。因此，加州是“处理地区”，美国其他州是可能的“控制地区”。
- 此时，可能我们立马就能想起来，可以使用**PSM**呀。
- **PSM——大样本**

- 我们接着来看加州控烟税的例子。为了避免其他州类似的政策对控制组产生影响，**Abadie**等剔除了研究期内出台相似控烟政策的州，最后潜在控制组里剩下**38**个州。也就是说样本包括美国**39**各州，**1970-2000**年的面板数据，变量包括：州年度人均香烟消费量、香烟平均零售价格、州人均收入对数、州人口结构（**15-24**岁比例）、州人均啤酒消费量等等。

记 Y_{it} 为地区 i 在 t 期实际观测到的结果变量，即香烟消费量。

记 Y_{it}^I 的上标 I 表示地区 i 接受政策干预，即这个变量表示加州在提高香烟消费税后的香烟消费量。同理， Y_{it}^N 的上标 N 表示没有受到政策干预。根据上文将的处理效应，我们实际上感兴趣的是：

$$ATE = Y_{it}^I - Y_{it}^N$$

现在的问题是， Y_{it}^N 观测不到，因此，我们要估计出它。那么，怎么估计呢？即书本上的”因子模型“来估计 Y_{it}^N ：

$$Y_{it}^N = \delta_t + \theta_t Z_i + \lambda_t \mu_i + \epsilon_{it} \quad (15)$$

- 上式右边第一项表示时间固定效应 (time fixed effects)。第二项表示可观测的向量（不受政策干预影响，也不随时间而变；比如，干预之前的预测变量之平均值），由于它对Y的效应随时间可变，因此，其系数 θ 有时间下标。第三项表示不可观测的“交互固定效应”（Interactive Fixed Effects），即个体固定效应 μ 与时间固定效应 λ 的乘积（Bai, 2009）。第(4)项为随机扰动项。
- 我们咋一看，这不就是面板回归吗？但是请注意，第三项“交互固定效应”是不可观测的变量。这一点很重要。

- 基本思想：虽然无法找到加州地区的最佳控制地区，但通常可对美国其他的若干州进行适当的线性组合，以构造一个更为贴切的“合成控制地区”（**synthetic control region**），并将“真实的加州地区”与“合成的加州地区”进行对比。

州地区”与“合成的加州地区”进行对比。也就是说，我们要利用其他州的线性组合来拟合出加州的 Y_{it}^N ，线性组合就是每个州的Y前面乘以一个权重W之和，假设每个州的权重用 w_j 表示，那么，我们将线性组合表示为

$$\sum_{j=1}^{j=N} w_j Y_{jt} = \delta_t + \theta_t \sum_{j=1}^{j=N} w_j Z_j + \lambda_t \sum_{j=1}^{j=N} w_j \mu_j + \sum_{j=1}^{j=N} w_j \epsilon_{jt} \quad (16)$$

- 用 (15) 减去 (16)

$$Y_{it}^N - \sum_{j=1}^{j=N} w_j Y_{jt} = \theta_t (Z_i - \sum_{j=1}^{j=N} w_j Z_j) + \lambda_t \sum_{j=1}^{j=N} (\mu_i - w_j \mu_j) + \sum_{j=1}^{j=N} (\epsilon_{it} w_j \epsilon_{jt}) \quad (17)$$

Diagram illustrating the equation (17) with annotations:

- The term $Y_{it}^N - \sum_{j=1}^{j=N} w_j Y_{jt}$ is enclosed in a red dashed box, with a vertical line pointing down to a red dashed box containing 0 .
- The term $Z_i - \sum_{j=1}^{j=N} w_j Z_j$ is enclosed in a red dashed box, with a vertical line pointing down to a red dashed box containing 0 .
- The term $\sum_{j=1}^{j=N} (\mu_i - w_j \mu_j)$ is enclosed in a red dashed box, with a vertical line pointing down to a red dashed box containing 0 .
- The term $\sum_{j=1}^{j=N} (\epsilon_{it} w_j \epsilon_{jt})$ is enclosed in a red dashed box, with a vertical line pointing down to a red dashed box containing 0 .
- The term $\mu_i - w_j \mu_j$ is enclosed in a red dashed box, with an arrow pointing up to a red dashed box containing "不可观测" (Unobservable).

- 那怎么办?

里面可观测的变量有干预前的 Y_{it} 、 Y_{jt} 、 Z_i 、 Z_j ，
那么，我们只需要找到最优的权重 w_j 使得：

$$Y_{it}^N - \sum_{j=1}^{j=N} w_j Y_{jt} = 0, Z_i - \sum_{j=1}^{j=N} w_j Z_j = 0$$

- Abadie et al. (2010) 已经证明了，当干预前的时期数趋向于无穷，那么，合成控制估计量就是无偏的。
- 小贴士：
- 合成控制法对样本数据的要求为政策干预以前需要很多期数据，有人认为至少需要**15**年的数据，而政策干预后需要有**5**年以上的数据。同时地区最好超过**10** 个，但是又不会太多。最为重要的是，接受政策干预的地区个数极少。

合成控制法stata操作

我们来继续看看加州控烟税政策的效果。

第一步，我们在stata中输入下列命令：

```
ssc install synth, replace    （下载并安装synth程序）
```

其中，选择项“replace”表示如有此命令更新版本，可以新命令覆盖旧命令。

命令synth的基本句型为：

```
synth y x1 x2 x3, trunit(#) trperiod(#) cunit(numlist) xperiod(numlist) mspeperiod() figure  
resultsperiod() nested allopt keep(filename)
```

第二步，打开数据集之后，输入下列命令：

xtset state year（声明面板数据）


第三步，在stata中输入下列合成控制法估计命令：

*synth cigsale retprice lnincome age15to24 beer cigsale(1975) cigsale(1980) cigsale(1988),
trunit(3) trperiod(1989) xperiod(1980(1)1988) figure nested keep(smoking_synth)*

州↵	权重↵	州↵	权重↵
Alabama↵	0↵	Nevada↵	.235↵
Arkansas↵	0↵	New Hampshire↵	0↵
Colorado↵	.161↵	New Mexico↵	0↵
Connecticut↵	.068↵	North Carolina↵	0↵
Delaware↵	0↵	North Dakota↵	0↵
Georgia↵	0↵	Ohio↵	0↵
Idaho↵	0↵	Oklahoma↵	0↵
Illinois↵	0↵	Pennsylvania↵	0↵
Indiana↵	0↵	Rhode Island↵	0↵
Iowa↵	0↵	South Carolina↵	0↵
Kansas↵	0↵	South Dakota↵	0↵
Kentucky↵	0↵	Tennessee↵	0↵
Louisiana↵	0↵	Texas↵	0↵
Maine↵	0↵	Utah↵	.335↵
Minnesota↵	0↵	Vermont↵	0↵
Mississippi↵	0↵	Virginia↵	0↵
Missouri↵	0↵	West Virginia↵	0↵
Montana↵	.201↵	Wisconsin↵	0↵
Nebraska↵	0↵	Wyoming↵	0↵



	Treated	Synthetic
retprice	89.42222	89.41464
lnincome	10.07656	9.858694
age15to24	.1735324	.1735444
beer	24.28	24.21326
cigsale(1975)	127.1	127.0633
cigsale(1980)	120.2	120.4545
cigsale(1988)	90.1	91.6356



更直观地，可打开另一Stata程序，调用已存的数据集smoking_synth.dta，计算加州与合成加州人均香烟消费之差（即处理效应），然后画图。

```
use smoking_synth.dta, clear
```

（如不打开另一Stata程序，则此数据集将覆盖原有的数据集smoking.dta）

```
gen effect = _Y_treated - _Y_synthetic
```

（定义处理效应为变量effect，其中“_Y_treated”与“_Y_synthetic”分别表示处理地区与合成控制的结果变量）

- Line effect `_time`, `xline(1989, lp(dash))` `yline(0,lp(dash))`



- 到此，我们关心的合成控制法主要结果都呈现出来了。但是在使用合成控制法时，如何进行稳健性检验与统计推断？
- 为了检验上述合成控制估计结果的稳健性，**Abadie et al. (2010)**加入了更多的预测变量，比如失业率、收入不平等、贫困率、福利转移、犯罪率、毒品相关的逮捕率、香烟税、人口密度等；发现结果依然稳健。

- 另外一个担心是，地区之间无互相影响（**no interference between units**）的假定可能不满足，比如加州的反烟运动可能波及其他州，烟草行业或将其他州的香烟广告预算投入到加州，甚至从其他州走私便宜香烟到加州。**Abadie et al. (2010)**根据史实对此进行了探讨，认为这些效应均不大，至少不可能导致上文图中如此大的处理效应。

注意事项

- 在使用合成控制法时，需要特别注意以下几点：
- 1、我们的是将没有实行政策的地区作为备选的合成控制组，但是如果i地区实行政策对j地区也产生了影响，那么，这个时候，我们就应该将j地区从备选控制组中提出掉，例如加州提高控烟税，对威斯康辛州有很大影响，那么，我们就应该将威斯康辛州从38个备选里去掉；
- 2、如果在研究期间，有一些地区受到非常大的特殊冲击，那么，这时候我们也要将其剔除；
- 3、尽量使得控制地区与处理地区具有相似的特征；

- 
- 4、合成控制法对样本数据的要求为政策干预以前需要很多期数据，有人认为至少需要**15**年的数据，而政策干预后需要有**5**年以上的数据。同时地区最好超过**10**个，但是又不会太多。最为重要的是，接受政策干预的地区个数极少。
 - 5、如果政策冲击的效应需要一段时间才会显现（滞后效应），则也要求干预后的期数足够大。

合成控制法与DID

- 首先，根据Abadie et al. (2010)的因子模型（**factor model**），合成控制法对双向固定效应模型作了推广。具体来说，双重差分法仅允许个体固定效应与个体时间效应以相加（**additive**）的形式存在，隐含假设所有个体的时间趋势都相同（**parallel trend assumption**）；而合成控制法的因子模型，则允许“互动固定效应”（**interactive fixed effects**），即可以存在多维的共同冲击（**common shocks**），而每位个体对于共同冲击的反应（**factor loading**）可以不同，故允许不同个体有不同的时间趋势。

- 其次，Abadie et al. (2015)指出，回归法也可以视为对控制地区作了线性组合，且权重之和也为1；而不同之处在于，合成控制法的权重必须非负，但回归法的权重可能出现负值，即出现过分外推（**extrapolation**）而离开了样本数据的取值范围（**support of the data**）。比如，在跨国研究中，将很不相同的国家放在一起进行回归，就可能出现过分外推，而导致“外推偏差”（**extrapolation bias**）。由于合成控制法的权重必须非负，故避免了过分外推。

第三讲 结构模型

动态随机一般均衡 (DSGE) 分析框架

使用情况

- 学术研究：宏观领域，Top 5 上 DSGEs 的文章超过 50% (Glandon et al., 2022)
- 决策机构：全球超过 80 个政策决策机构构建了官方的 DSGE 模型 (Yagihashi, 2020)

概念

- 动态 (Dynamic): 做决策依赖于“昨天、今天、明天”——既包括有限期 (两期), 也包括无限期
- 随机 (Stochastic): 做决策总要考虑不确定性——既包括外生的 (天气), 也包括内生的 (心情)
- 一般均衡 (General Equilibrium): 不仅有瓦尔拉斯的均衡, 还有纳什的均衡

因此, 从更广义、更实践的角度来看, 人们通常将 **DSGE** 指代增长与经济周期的定量分析框架 (Christiano et al., 2018)。

示例 1：周期模型

模型来源于 J Pfeifer(2020): 一个经典的货币经济 RBC 模型, 假设家庭无弹性地供给单位劳动, 即固定供给 $h_t = 1$, 忽略总人口的增长, 因此, 模型中的变量是人 (劳) 均量。

- 家庭的跨期效应函数

$$\underbrace{\max}_{C_t, I_t, K_t, B_t} E_0 \sum_{t=0}^{\infty} \beta^t \log(C_t)$$

- 家庭的约束
- (1) 约束约束: $C_t + I_t + \frac{B_t}{R_t} = Y_t + \frac{R_{t-1}B_{t-1}}{R_t}$
- (2) 产出约束: $Y_t = A_t K_{t-1}^{\alpha} (X_t h_t)^{1-\alpha} = A_t K_{t-1}^{\alpha} X_t^{1-\alpha}$
- (3) 资本积累: $K_t = I_t + (1 - \delta) K_{t-1}$
- 货币政策

$$\frac{R_t}{R} = \left(\frac{\Pi_t}{\Pi} \right)^{\phi}$$

示例 1：周期模型

这个模型经济的均衡条件：

- FOCs 条件

$$\frac{1}{C_t} = \beta E_t \frac{1}{C_{t+1}} [\alpha A_{t+1} K_t^{\alpha-1} X_{t+1}^{1-\alpha} + (1 - \delta)]$$

$$\frac{1}{C_t P_t} = \beta E_t \frac{1}{C_{t+1}} \frac{R_t}{P_{t+1}}$$

- 市场出清条件

$$C_t + K_t - (1 - \delta)K_{t-1} + \frac{B_t}{P_t} = Y_t + \frac{R_{t-1}B_{t-1}}{P_t}$$

- 货币政策

$$\frac{R_t}{R} = \left(\frac{\Pi_t}{\Pi} \right)^\phi$$

- 外生冲击

$$A_t = e^{z_t}$$

$$z_t = \rho z_{t-1} + \epsilon_t, \epsilon_t \sim N(0, \sigma^2)$$

$$X_t = 1$$

需要说明的几点：

- 1 . $A_t X_t^{1-\alpha}$ 是该模型经济的总技术变化，它包含平稳的技术变化和非平稳的技术变化，也可以理解成包含确定性增长趋势和随机性增长趋势。
- 2 . 该模型经济假设 $X_1 = 1$ ，为了研究平稳技术冲击对经济的影响，即外生技术冲击引起的经济（周期）波动。
- 3 . 在债券市场上，均衡的债券净额为 0，即 $B_t = 0$ 。
- 4 . $\Pi_t = \frac{P_t}{P_{t-1}}$ 定义通货膨胀。

Dynare 代码 1

代码片段 1: 货币经济 RBC 模型

```
1 // 声明内生变量
2 var y c k A z R Pi ;
3
4 // 声明外生变量
5 varexo eps_z ;
6
7 // 声明参数
8 parameters beta d e l t a alpha rhoz phi_pi Pibar ;
9
10 // 参数赋值
11 alpha = 0 . 3 3 ; // 资本份额
12 d e l t a = 0 . 0 2 5 ; // 折旧率
13 beta = 0 . 9 9 ; // 贴现率
14 Pibar = 1 ;
15 phi_pi = 1 . 5 ;
16 rhoz = 0 . 9 7 ;
17
18 // 声明模型
19 model ;
20 #Rbar = 1/ beta ;
21 1/ c=beta *1/ c (+1) *( alpha *A(+1)*k^( alpha 1)+(1 d
```

定量图




图 1: 技术冲击对宏观经济的影响




图 2: 产出的模拟路径

平衡增长路径 (BGP)

- 上述货币经济 RBC 模型并没有考虑经济的增长趋势，例如，模型经济将劳动扩增型技术进步 X_t 带来的增长完全忽略了。
- 因此，该模型仅仅只是描述了经济在平稳增长路径或者增长稳态附近的波动，因此，称之为“经济周期模型”。
- 误区：DSGE 只讨论经济周期问题。

示例 2：随机增长模型

- 现实经济肯定具有某种增长趋势，因此，宏观经济模型也应该明确刻画经济增长趋势。
- 最经典的经济增长趋势的设定：随机增长趋势——随机游走的形式，例如，NY DSGE。
- 下面，来看看随机增长趋势的增长模型。
- 在上述经典货币经济 RBC 模型的基础上扩展，引入随机增长趋势：人均产出的增长是由来自于人力资本 X_t 提升带来的技术进步。因此，可以假设人力资本 X_t 遵循一个随机游走过程

$$X_t = X_{t-1} e^{\Lambda_x + \epsilon_{x,t}}, \epsilon_{x,t} \sim N(0, \sigma_{x,t}^2)$$

两边取对数：

$$\log X_t = \log X_{t-1} + \Lambda_x + \epsilon_{x,t}$$

其中， Λ_x 表示人力资本的长期增长率（也是人均产出和其它宏观变量的长期增长率）， $\epsilon_{x,t}$ 表示人力资本的临时性冲击。

这个时候，增长模型的均衡条件：

- FOCs 条件

$$\frac{1}{C_t} = \beta E_t \frac{1}{C_{t+1}} [\alpha A_{t+1} K_t^{\alpha-1} X_{t+1}^{1-\alpha} + (1 - \delta)]$$

$$\frac{1}{C_t P_t} = \beta E_t \frac{1}{C_{t+1}} \frac{R_t}{P_{t+1}}$$

- 市场出清条件

$$C_t + K_t - (1 - \delta)K_{t-1} + \frac{B_t}{P_t} = A_t K_{t-1}^{\alpha} X_t^{1-\alpha} + \frac{R_{t-1} B_{t-1}}{P_t}$$

- 货币政策

$$\frac{R_t}{R} = \left(\frac{\Pi_t}{\Pi} \right)^{\phi}$$

- 外生冲击

$$A_t = e^{z_t}$$

$$z_t = \rho z_{t-1} + \epsilon_t, \epsilon_t \sim N(0, \sigma^2)$$

- 人力资本增长趋势

$$X_t = X_{t-1} e^{\Lambda_x + \epsilon_{x,t}}, \epsilon_{x,t} \sim N(0, \sigma_{x,t}^2)$$

$$\log X_t = \log X_{t-1} + \Lambda_x + \epsilon_{x,t}$$

为了建模出整个经济的增长率，我们用小写字母表示去增长趋势的变量，例如，一个变量 D_t 可以写成

$$D_t = d_t X_t$$

(1) 首先来看看市场出清条件/预算约束

$$C_t + K_t - (1 - \delta)K_{t-1} + \frac{B_t}{P_t} = A_t K_{t-1}^\alpha X_t^{1-\alpha} + \frac{R_{t-1} B_{t-1}}{P_t}$$

我们可以将其转换成：

$$c_t X_t + k_t X_t - (1 - \delta)k_{t-1} X_{t-1} + \frac{b_t X_t}{P_t} = A_t (k_{t-1} X_{t-1})^\alpha X_t^{1-\alpha} + \frac{R_{t-1} b_{t-1} X_{t-1}}{P_t}$$

两边同时除以 X_t ，得到

$$c_t + k_t - (1 - \delta)k_{t-1} \frac{1}{g_t} + \frac{b_t}{P_t} = A_t(k_{t-1} \frac{1}{g_t})^\alpha + \frac{R_{t-1}b_{t-1}}{P_t g_t}$$

其中， $g_t = \frac{X_t}{X_{t-1}}$ 表示经济增长率。

类似地，我们可以将其他的均衡条件也转换成带有增长率的情形：

(2) 欧拉方程：

$$\frac{1}{c_t} = \beta E_t \frac{1}{c_{t+1} g_{t+1}} [\alpha A_{t+1} (\frac{k_t}{g_{t+1}})^{\alpha-1} + (1 - \delta)]$$

$$\frac{1}{c_t P_t} = \beta E_t \frac{1}{c_{t+1} g_{t+1}} \frac{R_t}{P_{t+1}}$$

Dynare 代码 2

代码片段 2: 随机增长模型

```
1 // 声明内生变量
2 var y_t i lde c_t i lde k_t i lde z R_tilde Pi_t i lde
   mu_tilde ;
3
4 varexo eps_z eps_x ;
5
6 parameters beta d e l t a alpha rhoz phi_pi Pibar
   Lambda_x ;
7
8 alpha = 0 . 3 3 ; // c a p i t a l s h a r e
9 d e l t a = 0 . 0 2 5 ; // d e p r e c a t i o n r a t e
10 beta = 0 . 9 9 ; // d i s c o u n t f a c t o r
11 Pibar = 1 ;
12 phi_pi = 1 . 5 ;
13 rhoz = 0 . 9 7 ; //TFP a u t o c o r r . f r o m l i n e a r l
   y d e t r e n d e d S o l o w r e s i d u a l
14 Lambda_x= 0.0055 ;
15
16 model ;
17 #Rbar = exp (Lambda_x) / beta ;
18 1/ exp ( c_t i lde )=beta /exp (mu_tilde (+1) ) *1/ exp
```

定量图




图 3: 临时性增长率冲击

定量图




图 3: 临时性增长率冲击

波动影响增长

传统宏观经济学（研究）将经济周期和经济增长分开：

- 实际经济周期模型和新凯恩斯主义模型：外生的技术进步冲击或外生的随机增长冲击
- 内生增长模型：忽略了经济波动和失业等问题

全球金融危机和新冠危机让我们看到了经济波动也会影响到长期增长。




图 5: 发达经济体增长偏离金融危机前的趋势 (来源: Fornaro(2021))

示例 3：凯恩斯主义增长模型

模型来自于 Fornaro(2021): Keynesian Growth Model

- 需求疲软可能导致失业
- 企业技术投资驱动技术进步
- 衰退抑制投资，从而降低未来产出
- 货币政策和财政政策可以刺激技术投资和未来产出
- 分析框架：内生增长 + NK
- 代表性代理人的跨期效用函数

$$E_0 \sum_{t=0}^{\infty} \beta^t \log(C_t)$$

- L 表示经济中的劳动禀赋，可能由于工资粘性使得 $L_t < L$
- 家庭拥有企业，进入到债券市场，获得利率 i

$$\frac{1}{C_t} = \beta E_t \frac{1}{\pi_{t+1} C_{t+1}} (1 + i_t)$$

其中， $\pi_t = \frac{P_t}{P_{t-1}}$ 表示通胀率

- 生产企业

$$Y_t = L_t^{1-\alpha} \int_0^1 A_{j,t}^{1-\alpha} x_{j,t}^\alpha dj$$

其中， $x_{j,t}$ 表示技术进步的中投入。

- 每中产品 j 由代表性企业生产，一单位中间产品生产一单位的最终产品，因此， $MC_t = P_t$ ，那么， j 产品的最优定价为：

$$P_{j,t} = \frac{P_t}{\alpha}$$

$$\omega A_{jt} L_t$$

- 企业的垄断利润就是企业生产技术 A_{jt} 和劳动投入 L_t 的增函数
- 企业的技术投资：

$$A_{j,t+1} = A_{j,t} + \chi I_{j,t}$$

- 企业的最优投资决策要最大化企业利润

$$\max E_0 \sum_0^{\infty} \frac{\beta^t}{C_t} (\omega A_{j,t} Z_t L_t - I_{j,t})$$

- 假设企业是对称的，且投资总为正

$$\frac{1}{\chi} = E_t \left[\frac{\beta C_t}{C_{t+1}} (\omega L_{t+1} + \frac{1}{\chi}) \right]$$

- 投资的回报会随着未来市场规模的增加了上升
- 市场出清条件

$$Y_t - \int_0^1 x_{j,t} dj = C_t + I_t$$

- 劳动市场：完全就业 $L_t = L$ ，失业 $L_t < L$
- 内生增长率/技术进步率

$$g_{t+1} = \frac{A_{t+1}}{A_t} = 1 + \chi \frac{I_t}{A_t}$$

- 名义工资粘性

$$\frac{W_t}{W_{t-1}} = \pi_t \frac{A_t}{A_{t-1}}$$

- 价格

$$P_t = \frac{1}{1-\alpha} \left(\frac{1}{\alpha} \right)^{\frac{2\alpha}{1-\alpha}} \frac{W_t}{A_t}$$

- 货币政策

$$1 + i_t = (1 + i)(\pi_t)^{\phi_1} \left(\frac{L_t}{L}\right)^{\phi_2}$$

因此，凯恩斯主义增长模型的均衡条件

- 总需求函数

$$c_t = \frac{g_{t+1}}{\beta E_t [c_{t+1}^{-1}]} \frac{\bar{\pi}}{(1 + \bar{i}) \left(\frac{L_t}{L}\right)^{\varphi}} \text{ where } c_t \equiv \frac{C_t}{A_t}$$

- 内生增长函数

$$g_{t+1} = \beta E_t \left[\frac{c_t}{c_{t+1}} (\chi \varpi L_{t+1} + 1) \right]$$

- 市场出清

$$\Psi L_t = c_t + \frac{g_{t+1} - 1}{\chi}$$

dynare 代码 3

代码片段 3: 新凯恩斯主义增长模型

```
1  // 声明内生变量
2  var c g i l;
3
4  varexo ei;
5
6  parameters beta piss rho phi1 phi2 lss chi omega psi;
7
8  beta=0.9;
9  piss=1;
10 rho=0.9;
11 phi1=1.5;
12 phi2=1;
13 lss=1;
14 chi=0.1;
15 omega=0.1;
16 psi=1;
17
18 model;
19
20 1+i=(piss/beta)*piss^phi1*(1/lss)^phi2+ei;
21
```

总结

现在，学界基本已经形成一致意见：NK-DSGE 模型显然不适应危机后的经济情形。正如 Blanchard and Summers (2017) 指出，如大衰退和滞胀一样，这次金融危机必然会对宏观经济学带来深远的影响。这次危机会使得宏观经济学作出哪些改变仍然还在争论中。不过，似乎大部分学者都同意，宏观经济学会不断演进，而不太会出现“革命” (Vines and Wills, 2018)。而对于宏观经济模型来说，需要重构基准模型结构也已经成为共识。

- 金融因素
- 非理性预期
- 波动与增长的结合
- 策略互动
- 等等

A vibrant background image featuring a clear blue sky with scattered white clouds. A bright sun is visible in the upper center, creating a lens flare effect. The lower half of the image shows a lush green field, possibly a crop field, with a small tree visible on the left edge.

谢谢大家！